

Многомерный статистический анализ

Лабораторная работа №2

Классификация многомерных объектов при наличии обучающей выборки

Александр Безлепский
группа 5030102/10401

18 марта 2025 г.

Задание

В этой работе рассматривается проблема бинарной классификации многомерных данных при наличии обучающей выборки. Работа состоит из двух частей:

1. Классификация объектов с использованием дискриминантного анализа
2. Классификация объектов с использованием метода главных компонент

В качестве анализируемых данных предлагается использовать как модельные данные, так и данные реальных измерений из репозитория.

1 Работа с модельными данными

1.1 Моделирование обучающих выборок

Для задания **набора**, состоящего из двух *выборок* требуется задать 3 параметра: два вектора матожиданий $\mu^{(1)}, \mu^{(2)}$, компоненты которых представляют собой математические ожидания вдоль каждого измерения каждой *выборки* и симметричная положительно определённая матрица ковариации Σ , которая описывает характер распределения данных вдоль различных измерений, а именно:

- каждый элемент на главной диагонали представляет дисперсию (вариацию) соответствующей переменной. Он показывает, насколько значения этой переменной разбросаны вокруг среднего значения (соответствующего значения вектора матожидания). Чем выше дисперсия, тем данные сильнее разбросаны.
- недиагональные элементы представляют ковариацию между парами соответственных переменных, значения отличные от нуля означают наличие линейной зависимости между парой соответственных компонент данных.

Для первой части работы сформируем два **набора** p -мерных ($p = 3$) данных, состоящих из объектов двух классов. Сначала представим сбалансированные **наборы** с обучающими *выборками* равного размера $N_{\text{train}} = 500$ и тестовыми выборками размера $N_{\text{test}} = 100$.

Первый набор Ω_x (хорошо разделимый набор – х.р.н.) призван продемонстрировать хорошо разделимые данные; все характеристики, относящиеся к нему будем помечать подстрочной x . Второй набор Ω_{π} (плохо разделимый набор – п.р.н.) призван продемонстрировать плохо разделимые данные; все характеристики, относящиеся к нему будем помечать подстрочной π .

1.1.1 Хорошо разделимый набор данных

Зададим параметры Ω_x :

$$\mu_x^{(1)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \quad \mu_x^{(2)} = \begin{bmatrix} 5 \\ 5 \\ 5 \end{bmatrix}, \quad \Sigma_x = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

В языке Julia версии 1.11.4 создать такой набор данных можно следующей последовательностью команд:

```
1 julia> using Distributions, LinearAlgebra, Random; Random.seed!(1)
2 julia> N_train = 500
3 julia> mu_1 = [0, 0, 0]
4 julia> mu_2 = [5, 5, 5]
5 julia> Sigma = Diagonal([1, 1, 1])
6 julia> OV1 = rand(MvNormal(mu_1, Sigma), N_train)'
7 julia> OV2 = rand(MvNormal(mu_2, Sigma), N_train)'
```

этот набор можно визуализировать так:




Рис. 1: Общий вид Ω_x . На левом подграфике общий вид обучающих выборок (третье измерение передано цветом), а на правом – поверх оттенённых обучающих выборок наложены тестовые выборки.

Данные действительно хорошо разделимы, ожидаем высокую точность классификатора.

1.1.2 Плохо разделимый набор данных

Зададим параметры Ω_Π :

$$\mu_\Pi^{(1)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \quad \mu_\Pi^{(2)} = \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix}, \quad \Sigma_\Pi = \begin{bmatrix} 4.0 & -0.8 & 1.0 \\ -0.8 & 2.0 & 0.3 \\ 1.0 & 0.3 & 1.0 \end{bmatrix}$$

Этот набор можно аналогично визуализировать так:




Рис. 2: Общий вид Ω_Π . Отметим, что облака данных сильно пересекаются.

Даже воспользовавшись трёхмерной визуализацией и обозначив двумя цветами выборки разных классов подобрать угол обзора, при котором разделение максимально, непросто:




Рис. 3: Трёхмерная визуализация Ω_{Π} . Сверху: общий вид обучающих выборок, снизу: поверх оттенённых маркеров обучающих выборок наложены маркеры тестовых выборок

1.2 Вычисление выборочных оценок

1.2.1 Выборочные средние

Для класса k среднее значение j -го признака вычисляется как:

$$\hat{\mu}_j^{(k)} = \frac{1}{n_k} \sum_{i=1}^{n_k} x_{ij}^{(k)}, \quad j = \overline{1, p}, \quad k \in \{1, 2\}, \quad \text{где } p - \text{число признаков, } n_k = N_{\text{train}} = 500.$$

Что для наших данных (значения приводятся округлёнными):

$$\hat{\mu}_x^{(1)} = \begin{bmatrix} 0.022 \\ -0.026 \\ 0.053 \end{bmatrix}, \quad \hat{\mu}_x^{(2)} = \begin{bmatrix} 5.007 \\ 4.920 \\ 5.046 \end{bmatrix}; \quad \hat{\mu}_\pi^{(1)} = \begin{bmatrix} 0.068 \\ -0.049 \\ -0.004 \end{bmatrix}, \quad \hat{\mu}_\pi^{(2)} = \begin{bmatrix} 0.923 \\ 2.018 \\ 0.002 \end{bmatrix}.$$

Заметим, что вектора выборочных средних отличаются от векторов матожиданий, на основе которых генерировались выборки, хотя и близки к ним.

1.2.2 Выборочные ковариационные матрицы

Выборочная ковариационная матрица $S^{(k)}$ для каждого класса k служит оценкой теоретической ковариационной матрицы $\Sigma^{(k)}$ на основе обучающей выборки. Элемент $s_{lj}^{(k)}$ матрицы $S^{(k)}$ вычисляется по формуле:

$$s_{lj}^{(k)} = \frac{1}{n_k - 1} \sum_{i=1}^{n_k} \left(x_{il}^{(k)} - \hat{\mu}_l^{(k)} \right) \left(x_{ij}^{(k)} - \hat{\mu}_j^{(k)} \right),$$

где $n_k = 500$ – размер обучающей выборки для класса k , а $\hat{\mu}_l^{(k)}$ и $\hat{\mu}_j^{(k)}$ – выборочные средние для l -го и j -го признаков соответственно. При $l = j$, элемент $s_{jj}^{(k)}$ представляет собой выборочную дисперсию j -го признака, показывающую разброс значений вокруг среднего. $n_k - 1$ в знаменателе обеспечивает несмещённость оценки.

В нашем случае:

$$S_x^{(1)} = \begin{bmatrix} 1.061 & 0.093 & -0.033 \\ 0.093 & 1.011 & 0.051 \\ -0.033 & 0.051 & 1.036 \end{bmatrix}; \quad S_\pi^{(1)} = \begin{bmatrix} 3.813 & -0.809 & 0.850 \\ -0.809 & 1.974 & 0.350 \\ 0.850 & 0.350 & 0.914 \end{bmatrix};$$
$$S_x^{(2)} = \begin{bmatrix} 0.997 & 0.025 & 0.012 \\ 0.025 & 1.034 & -0.063 \\ 0.012 & -0.063 & 0.875 \end{bmatrix}; \quad S_\pi^{(2)} = \begin{bmatrix} 3.640 & -0.616 & 0.956 \\ -0.616 & 1.967 & 0.257 \\ 0.956 & 0.257 & 0.913 \end{bmatrix}.$$

Для хорошо разделимого набора Ω_x теоретическая ковариационная матрица Σ_x задана как единичная матрица, что означает отсутствие корреляции между признаками и одинаковую дисперсию вдоль всех измерений. Выборочные матрицы $S_x^{(1)}$ и $S_x^{(2)}$ близки к единичной, что подтверждает хорошее соответствие сгенерированных данных заданным параметрам. Для плохо разделимого набора Ω_π матрица Σ_π содержит недиагональные элементы, указывающие на наличие корреляций между признаками, что отражено в $S_\pi^{(1)}$ и $S_\pi^{(2)}$.

1.2.3 Объединённые ковариационные матрицы

Объединённая ковариационная матрица S используется в линейном дискриминантном анализе (LDA) при предположении, что ковариационные матрицы обоих классов одинаковы ($\Sigma^{(1)} = \Sigma^{(2)} = \Sigma$). Она вычисляется как взвешенное среднее выборочных ковариационных матриц:

$$S = \frac{1}{n_1 + n_2 - 2} \left[(n_1 - 1)S^{(1)} + (n_2 - 1)S^{(2)} \right],$$

где $n_1 = n_2 = 500$. Такое усреднение позволяет получить более устойчивую оценку общей ковариационной структуры данных, что особенно важно для построения надёжного классификатора. Рассчитаем для наших наборов:

$$S_x = \begin{bmatrix} 1.029 & 0.059 & -0.011 \\ 0.059 & 1.023 & -0.006 \\ -0.011 & -0.006 & 0.956 \end{bmatrix}; \quad S_\pi = \begin{bmatrix} 3.727 & -0.713 & 0.903 \\ -0.713 & 1.971 & 0.303 \\ 0.903 & 0.303 & 0.913 \end{bmatrix};$$

1.2.4 Вектора коэффициентов дискриминантных функций

Вектор коэффициентов дискриминантной функции $\mathbf{a}$ в LDA определяет направление, вдоль которого проекции данных из разных классов максимально разделены. Он вычисляется по формуле:

$$\boldsymbol{\alpha} = \Sigma^{-1}(\boldsymbol{\mu}^{(1)} - \boldsymbol{\mu}^{(2)}) \implies \hat{\boldsymbol{\alpha}} = \mathbf{a} = S^{-1}(\hat{\boldsymbol{\mu}}^{(1)} - \hat{\boldsymbol{\mu}}^{(2)}).$$

где S – объединённая ковариационная матрица, а $\hat{\mu}^{(1)}$ и $\hat{\mu}^{(2)}$ – выборочные средние для классов 1 и 2. Этот вектор оптимален в смысле максимизации отношения межклассовой дисперсии к внутриклассовой, что обеспечивает эффективную классификацию.

Рассчитаем для двух наших наборов:

$$\mathbf{a}_x = \begin{bmatrix} -4.635 \\ -4.599 \\ -5.306 \end{bmatrix}, \quad \mathbf{a}_\pi = \begin{bmatrix} -0.860 \\ -1.570 \\ 1.365 \end{bmatrix}$$

1.2.5 Расстояние Махаланобиса

Расстояние Махаланобиса D^2 измеряет стандартизированное различие между многомерными распределениями двух классов, учитывая ковариационную структуру данных:

$$D^2 = (\hat{\mu}^{(1)} - \hat{\mu}^{(2)})^T S^{-1} (\hat{\mu}^{(1)} - \hat{\mu}^{(2)}),$$

где $\hat{\mu}^{(k)}$ – векторы выборочных средних значений признаков для класса k , а S – объединённая ковариационная матрица. Для коррекции смещения при малых выборках или высокой размерности p используется модифицированная формула:

$$D_H^2 = \frac{n_1 + n_2 - p - 3}{n_1 + n_2 - 2} D^2 - p \left(\frac{1}{n_1} + \frac{1}{n_2} \right),$$

где $p = 3$ (количество признаков). Для $n_1 = n_2 = 500$ поправка незначительна, но сохранена для общности.

Рассчитаем расстояния:

$$D_x^2 = 72.355, \quad D_\pi^2 = 3.972.$$

Применим поправку для смещения:

$$\boxed{D_{H,x}^2 = 72.053}, \quad \boxed{D_{H,\pi}^2 = 3.944}.$$

Разница почти в 20 раз между D_x^2 и D_π^2 подтверждает, что хорошо разделимый набор имеет значительно бóльшую межклассовую разделимость.

1.2.6 Теоретическая оценка вероятности ошибочной классификации

Теоретические вероятности ошибочной классификации $\hat{P}(2|1)$ и $\hat{P}(1|2)$ основаны на предположении нормальности проекций на дискриминантную ось.

Полная формула ошибок:

$$\hat{P}(2|1) = \Phi \left(\frac{K - \frac{1}{2} D_H^2}{D_H} \right), \quad \hat{P}(1|2) = \Phi \left(\frac{-K - \frac{1}{2} D_H^2}{D_H} \right)$$

Где:

- $\Phi(x)$ – функция распределения стандартного нормального распределения;
- $D_H = \sqrt{D_H^2}$;
- $K = \ln \left(\frac{q_2 c(1|2)}{q_1 c(2|1)} \right)$;
- D_H^2 – несмещенное расстояние Махаланобиса;
- $c(i|j)$ – стоимость ошибочной классификации объекта класса j как объект класса i ;
- q_1, q_2 – Априорные вероятности появления каждого класса.

При равных априорных вероятностях ($q_1 = q_2 = \frac{1}{2}$) и равных стоимостях ошибок ($c(1|2) = c(2|1)$), $K = 0$, и вероятности симметричны:

$$\hat{P}(2|1) = \hat{P}(1|2) = \Phi \left(-\frac{D_H}{2} \right),$$

Получим для Ω_x теоретическую оценку ошибок:

$$\hat{P}_x(2|1) = \hat{P}_x(1|2) \approx 1.097 \cdot 10^{-5} < 0.01\%$$

вероятности крайне малы, что указывает на отличную разделимость. Для Ω_π :

$$\hat{P}_\pi(2|1) = \hat{P}_\pi(1|2) \approx 0.160 = 16.0\%$$

вероятности, напротив, значительны. Вполне ожидаемо.

1.3 Классификатор

1.3.1 Построение классификатора

Для классификации тестовой выборки задаём пороговое значение. Пусть априорные вероятности классов равны q_1 и q_2 ; тогда порог определяется по формуле:

$$\tau = \frac{\bar{z}^{(1)} + \bar{z}^{(2)}}{2} + \ln \frac{q_2}{q_1}.$$

Где $\bar{z}^{(j)}$ среднее значение проекции точек j -й выборки на дискриминационную ось. В нашем случае обучающие выборки принимались равного размера N_{train} , соответственно априорные вероятности классов равны $\frac{1}{2}$ и второй член в классификаторе нулевой.

Так, для Ω_x получим $\tau_x = \frac{-0.263 + (-72.618)}{2} = -36.441$;

Для Ω_{Π} получим $\tau_{\Pi} = \frac{0.013 + (-3.959)}{2} = -1.973$.

Так или иначе для тестового трёхмерного вектора $\mathbf{x} = (x_1, x_2, x_3)^T$ и вектора коэффициентов дискриминантной функции $\mathbf{a} = (a_1, a_2, a_3)^T$ классификационное правило выглядит следующим образом:

$$\begin{cases} \text{Принадлежность к классу 1,} & \text{если } (\mathbf{a}, \mathbf{x}) \geq \tau, \\ \text{Принадлежность к классу 2,} & \text{если } (\mathbf{a}, \mathbf{x}) < \tau. \end{cases}$$

1.4 Эмпирическая оценка вероятности ошибочной классификации

Для эмпирической оценки произведём классификацию обучающих выборок и заполним таблицу сопряжённости:

	Присвоен класс 1	Присвоен класс 2
Истинный класс 1	m_{11}	m_{12}
Истинный класс 2	m_{21}	m_{22}

где m_{ij} — число объектов истинного класса i , отнесённых к классу j .

Эмпирические вероятности ошибочной классификации оцениваются по формулам:

$$\hat{f}(1|2) = \frac{m_{21}}{n_2}, \quad \hat{f}(2|1) = \frac{m_{12}}{n_1}.$$

Для хорошо разделимых данных получим:

	Присвоен класс 1	Присвоен класс 2
Истинный класс 1	500	0
Истинный класс 2	0	500

$$\hat{f}_x(1|2) = \hat{f}_x(2|1) = \frac{0}{500} = 0.$$

Для плохо разделимых данных получим:

	Присвоен класс 1	Присвоен класс 2
Истинный класс 1	428	72
Истинный класс 2	84	416

$$\hat{f}_{\Pi}(2|1) = \frac{72}{500} = 0.144, \quad \hat{f}_{\Pi}(1|2) = \frac{84}{500} = 0.168.$$

Из предпосылки симметричности следует, что вероятности ошибок бинарного классификатора равны, поэтому можно усреднить эти значения: $\frac{1}{2}(0.168 + 0.144) = 0.156$, что близко к теоретической оценке полученной выше.

1.4.1 Классификация

Произведём классификацию двух наших наборов данных размера N_{test} и составим таблицы сопряжённости на основе которых можно рассчитать общую точность классификации как долю правильно классифицированных объектов от общего числа классифицированных объектов:

$$\text{Асс} = \frac{m_{11} + m_{22}}{m_{11} + m_{12} + m_{21} + m_{22}}$$

1. Хорошо разделимые данные:

	Присвоен класс 1	Присвоен класс 2
Истинный класс 1	100	0
Истинный класс 2	0	100

$$\text{Асс}_x = 1$$

2. Плохо разделимые данные:

	Присвоен класс 1	Присвоен класс 2
Истинный класс 1	83	17
Истинный класс 2	13	87

$$f(2|1) = 0.135, \quad f(1|2) = 0.163, \quad \boxed{\text{Асс}_{\Pi} = 0.850}$$

1.5 Анализ результатов

В данной работе были проанализированы два набора данных: хорошо разделимый (Ω_x) и плохо разделимый (Ω_{Π}). Для каждого набора с использованием линейного дискриминантного анализа (LDA) построены классификаторы, а вероятности ошибочной классификации оценены как теоретически, так и эмпирически на обучающих и тестовых выборках.

Различие между оценками ошибок для Ω_{Π} и реальным количеством ошибок объясняется случайной вариацией в данных и меньшим расстоянием Махаланобиса ($D_{H,\Pi}^2 = 3.944$), что указывает на значительное пересечение классов из-за близости средних ($\mu_{\Pi}^{(1)} = [0, 0, 0]^T$, $\mu_{\Pi}^{(2)} = [1, 2, 0]^T$) и наличия корреляций в Σ_{Π} .

Таким образом, классификатор LDA показал идеальную точность для Ω_x , что подчёркивает его эффективность для хорошо разделимых данных. Для Ω_{Π} он допускает ошибки на уровне, предсказанном теоретически, что согласуется с пересечением классов. Эти результаты демонстрируют, как структура данных влияет на качество классификации, и подчёркивают важность анализа разделимости перед выбором метода.

2 Использование РСА

В данной части работы мы применим метод главных компонент (Principal Component Analysis, PCA) для анализа многомерных данных. Метод PCA позволяет снизить размерность данных, сохраняя при этом максимальную вариацию, что упрощает визуализацию и анализ структуры данных. В дальнейшем мы используем этот метод для проекции данных в пространство меньшей размерности для дальнейшей классификации.

2.1 Нахождение главных компонент

2.1.1 Объединение обучающих выборок

Первым шагом при применении PCA является объединение обучающих выборок обоих классов в единый набор данных. Это необходимо, поскольку PCA анализирует общую вариацию в данных, не учитывая принадлежность объектов к классам. Для каждого из наборов данных – хорошо разделимого Ω_x и плохо разделимого Ω_{Π} – мы формируем объединённые обучающие выборки. В сессии языка Julia это легко сделать вертикальной конкатенацией двух матриц:

```
1 julia> X = vcat(OV1, OV2)
```

Обозначим количество объектов в обучающей выборке первого класса как $N_{\text{train}}^{(1)}$, а второго класса – как $N_{\text{train}}^{(2)}$. Тогда общее число объектов в объединённой выборке равно:

$$N = N_{\text{train}}^{(1)} + N_{\text{train}}^{(2)}.$$

```
1 julia> N = size(X, 1)
```

Для наших данных $N_{\text{train}}^{(1)} = 500$ и $N_{\text{train}}^{(2)} = 500$, следовательно, $N = 1000$. Объединённая выборка для хорошо разделимого набора обозначается как X_x , а для плохо разделимого – как X_{Π} . Каждый объект в этих выборках представлен трёхмерным вектором, то есть X_x и X_{Π} – матрицы размером N строк на 3 столбца.

2.1.2 Центрирование данных

Перед применением PCA необходимо центрировать данные, чтобы главные компоненты отражали направления максимальной вариации относительно начала координат. Центрирование заключается в вычитании среднего значения каждого признака из соответствующих элементов выборки.

Для объединённой выборки X вычисляем среднее значение по каждому из трёх признаков:

$$\bar{x}_j = \frac{1}{N} \sum_{i=1}^N x_{ij}, \quad j = 1, 2, 3,$$

где x_{ij} – значение j -го признака для i -го объекта, а $\bar{x}_j$ – среднее значение j -го признака. Центрирование можно осуществить следующей командой:

```
1 julia> mean_X = mean(X, dims=1)
```

Получим следующие вектора:

$$\bar{\mathbf{x}}_x = \begin{bmatrix} 2.515 \\ 2.447 \\ 2.550 \end{bmatrix}; \quad \bar{\mathbf{x}}_n = \begin{bmatrix} 0.495 \\ 0.984 \\ -0.001 \end{bmatrix};$$

Затем выполняем центрирование данных:

$$\tilde{x}_{ij} = x_{ij} - \bar{x}_j, \quad i = \overline{1, N}, \quad j = 1, 2, 3.$$

```
1 julia> X_cent = X .- mean_X
```

В результате получаем центрированные матрицы $\tilde{X}_x$ и $\tilde{X}_n$ размерами $N \times 3$, строки которой соответствуют объектам, а столбцы – признакам. приводить их здесь целиком не целесообразно.

2.1.3 Вычисление ковариационной матрицы

Для центрированных данных вычисляем выборочную ковариационную матрицу S , которая характеризует вариацию и взаимосвязи между признаками. Формула для вычисления S :

$$S = \frac{1}{N-1} \tilde{X}^T \tilde{X},$$

где $\tilde{X}^T$ – транспонированная матрица центрированных данных размером $3 \times N$, а $\tilde{X}$ – матрица размером $N \times 3$. Матрица S имеет размер 3×3 , является симметричной и положительно полуопределённой.

```
1 julia> S = inv(N-1) * X_cent' * X_cent
```

Для наших наборов данных:

$$S_x = \begin{bmatrix} 7.246 & 6.230 & 6.219 \\ 6.230 & 7.146 & 6.176 \\ 6.219 & 6.176 & 7.195 \end{bmatrix}; \quad S_n = \begin{bmatrix} 3.906 & -0.270 & 0.903 \\ -0.270 & 3.038 & 0.306 \\ 0.903 & 0.306 & 0.912 \end{bmatrix}.$$

2.1.4 Нахождение собственных значений и собственных векторов

Следующим шагом является разложение ковариационной матрицы S на собственные значения и собственные векторы. Мы находим собственные значения $\lambda_1, \lambda_2, \lambda_3$ и соответствующие им собственные векторы $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$. Собственные значения упорядочиваем по убыванию:

$$\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq 0.$$

```
1 julia> egvals, egvecs = eigen(S)
2 julia> prmt = sortperm(egvals; rev=true)
3 julia> egvals_sorted = egvals[prmt]
4 julia> evecs_sorted = normalize.(eachcol(egvecs)[prmt])
```

Каждый собственный вектор $\mathbf{v}_j$ нормируем так, чтобы его длина была равна единице:

$$\begin{aligned} \lambda_{x,1} &= 19.612 \\ \lambda_{x,2} &= 1.009, \quad \mathbf{v}_{x,1} = \begin{bmatrix} -0.580 \\ -0.575 \\ -0.577 \end{bmatrix}, \quad \mathbf{v}_{x,2} = \begin{bmatrix} -0.475 \\ -0.336 \\ 0.813 \end{bmatrix}, \quad \mathbf{v}_{x,3} = \begin{bmatrix} 0.662 \\ -0.746 \\ 0.079 \end{bmatrix}. \\ \lambda_{x,3} &= 0.996 \\ \\ \lambda_{n,1} &= 4.185 \\ \lambda_{n,2} &= 3.065, \quad \mathbf{v}_{n,1} = \begin{bmatrix} -0.956 \\ 0.158 \\ -0.249 \end{bmatrix}, \quad \mathbf{v}_{n,2} = \begin{bmatrix} -0.113 \\ -0.976 \\ -0.186 \end{bmatrix}, \quad \mathbf{v}_{n,3} = \begin{bmatrix} -0.272 \\ -0.150 \\ 0.950 \end{bmatrix}. \\ \lambda_{n,3} &= 0.605 \end{aligned}$$

Собственные векторы $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ представляют собой направления главных компонент, а соответствующие собственные значения $\lambda_1, \lambda_2, \lambda_3$ показывают величину вариации данных вдоль этих направлений. Первая главная компонента $\mathbf{v}_1$ соответствует направлению максимальной вариации, вторая $\mathbf{v}_2$ – ортогональному направлению с следующей по величине вариацией, и так далее.

По значениям собственных чисел можно рассчитать, какая доля общей дисперсии объясняется каждой компонентой. Общая вариация это сумма полученных собственных чисел: $\text{Var}_{\text{tot}} = \sum_{i=1}^p \lambda_i$, а индивидуальная доля объяснённой дисперсии: $\text{Var}_i = \frac{\lambda_i}{\text{Var}_{\text{tot}}}$. Получаем для Ω_x :

$$\begin{aligned} \text{PC1: } \text{Var}_{x,1} &= \frac{19.612}{21.587} = 0.909 = 90.9\% \\ \text{PC2: } \text{Var}_{x,2} &= \frac{1.009}{21.587} = 0.047 = 4.7\% \\ \text{PC3: } \text{Var}_{x,3} &= \frac{0.996}{21.587} = 0.045 = 4.5\% \end{aligned}$$

То есть более 90% дисперсии объясняется первой главной компонентой. Ожидаем, что двигаясь вдоль первой оси, мы сможем проще всего предсказывать классы.

Для Ω_n :

$$\begin{aligned} \text{PC1: } \text{Var}_{n,1} &= \frac{4.185}{7.856} = 0.533 = 53.3\% \\ \text{PC2: } \text{Var}_{n,2} &= \frac{3.065}{7.856} = 0.390 = 39.0\% \\ \text{PC3: } \text{Var}_{n,3} &= \frac{0.605}{7.856} = 0.077 = 7.7\% \end{aligned}$$

Здесь ситуация другая: вторая главная компонента тоже вносит значительный вклад в объяснение дисперсии данных.

2.1.5 Проекция данных на главные компоненты

Для визуализации данных мы проецируем их на пространство любых двух главных компонент, что позволяет снизить размерность с трёх до двух. Формируем матрицу проекции V , состоящую из первых двух собственных векторов, конкатенируя два вектора-столбца в матрицу, например для первой и второй г.к.:

$$V = [\mathbf{v}_1, \mathbf{v}_2],$$

```
1 julia> V = hcat(evecs_sorted[1:2]...)
```

где V – матрица размером 3×2 .

$$V_x = \begin{bmatrix} -0.580 & -0.475 \\ -0.575 & -0.336 \\ -0.577 & 0.813 \end{bmatrix}; \quad V_{\Pi} = \begin{bmatrix} -0.956 & -0.113 \\ 0.158 & -0.976 \\ -0.249 & -0.186 \end{bmatrix}$$

Затем вычисляем проекции центрированных обучающих данных:

$$Z = \tilde{X}V,$$

```
1 julia> Z = X_cent * V
```

где Z – матрица размером $N \times 2$, содержащая координаты объектов в пространстве первых двух главных компонент.

Для тестовых выборок процесс аналогичен, но используются средние значения, вычисленные на обучающей выборке. Пусть X_{test} – тестовая выборка размером $N_{\text{test}} \times 3$. Центрируем тестовые данные:

$$\tilde{x}_{\text{test},ij} = x_{\text{test},ij} - \bar{x}_j, \quad i = 1, \dots, N_{\text{test}}, \quad j = 1, 2, 3,$$

где $\bar{x}_j$ – средние, полученные на этапе центрирования обучающей выборки. Затем проецируем:

$$Z_{\text{test}} = \tilde{X}_{\text{test}}V,$$

где $\tilde{X}_{\text{test}}$ – центрированная тестовая матрица, а Z_{test} – матрица проекций тестовых данных размером $N_{\text{test}} \times 2$. В нашем случае мы получили матрицы $Z_x, Z_{\Pi}, Z_{x,\text{test}}$ и $Z_{\Pi,\text{test}}$.

Определить, к какому классу относится точка, помогут определённые ранее N_{train} и N_{test} , а точнее, в обучающих матрицах все строки $j = \overline{1, N_{\text{train}}}$ относятся к первому классу, а строки $j = \overline{N_{\text{train}} + 1, 2N_{\text{train}}}$ – ко второму. Точно так же, в тестовых матрицах все строки $j = \overline{1, N_{\text{test}}}$ относятся к первому классу, а строки $j = \overline{N_{\text{test}} + 1, 2N_{\text{test}}}$ – ко второму.

2.1.6 Визуализация

Далее, после того, как $Z_x, Z_{\Pi}, Z_{x,\text{test}}$ и $Z_{\Pi,\text{test}}$ получены, осуществим визуализацию, чтобы получить первое представление о том, стояла ли игра свеч:




Рис. 4: Общий вид (ненормированных) собственных векторов Ω_x , отложенных от центроида

Теоретические предположения о распределении точек, основанных на величине собственных чисел, подтвердились: поскольку набор естественным образом (по генерации) вытянут, то не удивительно, что первый собственный вектор отлично ухватил это направление, а два других приблизительно равны и лишь отражают внутреннюю дисперсию двух выборок. В этом случае для понижения размерности подойдёт любая пара собственных векторов, одним из которых должен быть $\mathbf{v}_{x,1}$.

Так, в проекции на базис $(\mathbf{v}_{x,1}, \mathbf{v}_{x,2})$ получим:




Рис. 5: Ω_x спроецированный на первую и вторую главные компоненты. На правом изображении тестовые выборки наложены на обучающие

Также отметим, что данные действительно центрированы. Их разделимость не вызывала вопросов с самого начала, поэтому перейдём скорее к более интересному случаю плохо разделимых данных, где ситуация неоднозначнее:




Рис. 6: Общий вид (ненормированных) собственных векторов Ω_{Π} , отложенных от центроида

Облако точек сплюснуто вдоль наклонной плоскости, нормалью к которой можно считать самый короткий третий собственный вектор $\mathbf{v}_{\Pi,3}$, и нетривиальная матрица ковариации Σ_{Π} усложняет поиск направления высокой дисперсии, по которому бы разделились и классы. Попробуем спроецировать точки на базис $(\mathbf{v}_{\Pi,1}, \mathbf{v}_{\Pi,2})$:




Рис. 7: Ω_{π} спроецированный на первую и вторую главные компоненты.

И сразу отмечаем, что, хотя первая компонента захватывает самую большую часть дисперсии, классы вдоль неё, в отличие от второй компоненты, не разделяются. Между двумя классами можно визуальнo прочертить примерно вертикальную полосу разделения, однако она сильно размыта взаимным проникновением облаков точек друг в друга. Попробуем ($v_{\pi,2}, v_{\pi,3}$):




Рис. 8: Ω_{π} спроецированный на вторую и третью главные компоненты.

Здесь же полоса более наклонённая, на левой картинке можно примерно представить линию раздела от 11:00 до 17:00. В то же время эта полоса кажется менее зашумлённой, чем на Рис. 7.

2.2 Построение классификатора по новым признакам

Работать с тривиальным Ω_x не очень интересно, поэтому сконцентрируемся сейчас на анализе плохо разделяемого Ω_{π} . Сравним классификацию в проекциях на два базиса:

1. $(\mathbf{v}_{п,1}, \mathbf{v}_{п,2})$ – назовём этот набор данных $\Omega_{п}^{(1,2)}$;

2. $(\mathbf{v}_{п,2}, \mathbf{v}_{п,3})$ – этот назовём $\Omega_{п}^{(2,3)}$.

Рассчитаем же все необходимые значения и составим сравнительную таблицу для двух базисов:

Название	Обозначение	$\Omega_{п}^{(1,2)}$	$\Omega_{п}^{(2,3)}$
Размерность	p	2	2
Выборочное среднее класса 1	$\hat{\mu}^{(1)}$	$\begin{bmatrix} 0.246 \\ 1.058 \end{bmatrix}$	$\begin{bmatrix} 1.058 \\ 0.268 \end{bmatrix}$
Выборочное среднее класса 2	$\hat{\mu}^{(2)}$	$\begin{bmatrix} -0.246 \\ -1.058 \end{bmatrix}$	$\begin{bmatrix} -1.058 \\ -0.268 \end{bmatrix}$
Выборочная матрица ковариации класса 1	S_1	$\begin{bmatrix} 4.209 & -0.341 \\ -0.341 & 1.946 \end{bmatrix}$	$\begin{bmatrix} 1.946 & -0.347 \\ -0.347 & 0.547 \end{bmatrix}$
Выборочная матрица ковариации класса 2	S_2	$\begin{bmatrix} 4.050 & -0.180 \\ -0.180 & 1.949 \end{bmatrix}$	$\begin{bmatrix} 1.949 & -0.221 \\ -0.221 & 0.521 \end{bmatrix}$
Объединённая матрица ковариации	S	$\begin{bmatrix} 4.129 & -0.260 \\ -0.260 & 1.947 \end{bmatrix}$	$\begin{bmatrix} 1.947 & -0.284 \\ -0.284 & 0.534 \end{bmatrix}$
Вектор дискриминантной функции	$\mathbf{a}$	$\begin{bmatrix} 0.189 \\ 1.111 \end{bmatrix}$	$\begin{bmatrix} 1.337 \\ 1.717 \end{bmatrix}$
Расстояние Махаланобиса	$\bar{D}^2$	2.444	3.749
Скорректированное расстояние	D_H^2	2.428	3.730
Ср. проекция выборки 1 кл. на дискр. ось	$\bar{z}^{(1)}$	1.222	1.874
Ср. проекция выборки 2 кл. на дискр. ось	$\bar{z}^{(2)}$	-1.222	-1.874
Пороговое значение дискриминатора	τ	0	0
Теор. вер-то принять 1й класс за 2й	$\hat{P}(2 1)$	0.218	0.167
Теор. вер-то принять 2й класс за 1й	$\hat{P}(1 2)$	0.218	0.167
Эмпир. вер-то принять 1й класс за 2й	$\hat{f}(2 1)$	0.224	0.168
Эмпир. вер-то принять 2й класс за 1й	$\hat{f}(1 2)$	0.238	0.168
Частота принятия 1го класса за 2й на тесте	$f(2 1)$	0.189	0.158
Частота принятия 2го класса за 1й на тесте	$f(1 2)$	0.245	0.190
Точность классификатора	Асс	0.780	0.825

2.3 Анализ результатов классификации после понижения размерности

Применение метода главных компонент (РСА) к плохо разделимому набору данных $\Omega_{п}$ позволило выявить ключевые особенности, влияющие на качество классификации. Анализ двух вариантов проекций – на первые две главные компоненты $(\mathbf{v}_1, \mathbf{v}_2)$ и на вторую и третью компоненты $(\mathbf{v}_2, \mathbf{v}_3)$ – продемонстрировал принципиально разные результаты, что подчёркивает важность выбора подходящего подпространства для снижения размерности.

1. Проекция на первые две компоненты $(\mathbf{v}_1, \mathbf{v}_2)$:

- Объяснённая дисперсия: 53.3% (PC1) и 39.0% (PC2), суммарно 92.3%;
- Несмотря на высокую долю объяснённой дисперсии, расстояние Махаланобиса ($D_H^2 = 2.428$) и точность классификации (Асс = 0.780) оказались относительно низкими. Это связано с тем, что основная вариация, захваченная PC1, обусловлена внутриклассовым разбросом, а не межклассовым различием. Направление максимальной дисперсии совпадает с «размазанностью» данных внутри каждого класса, что не способствует их разделению.

2. Проекция на вторую и третью компоненты $(\mathbf{v}_2, \mathbf{v}_3)$:

- Объяснённая дисперсия: 39.0% (PC2) и 7.7% (PC3), суммарно 46.7%;
- Несмотря на меньшую долю объяснённой дисперсии, расстояние Махаланобиса ($D_H^2 = 3.730$) и точность (Асс = 0.825) увеличились. Это указывает на то, что вторая и третья компоненты содержат информацию о межклассовых различиях, "маскируемую" в исходном пространстве шумом и корреляциями. Направление PC2, ортогональное PC1, лучше отражает смещение центроидов классов, что подтверждается визуализацией.

Ключевые выводы:

- Максимальная дисперсия не гарантирует эффективного разделения классов. В данном случае PC1, объясняющая 53.3% дисперсии, оказалась менее информативной для классификации, чем PC2.
- Сравнительный анализ двух базисов, составленных из векторов главных компонент может выявить скрытые направления, улучшающие разделимость. Это особенно актуально для данных с пересекающимися распределениями и в случае высокой скоррелированных выборок.
- Метод не учитывает метки классов, что после понижения размерности может привести к потере информации о межклассовых различиях. В таких случаях стоит остановиться на LDA, который, как мы видим, продемонстрировал лучшие показатели точности: Асс_п = 0.850.

3 Работа с данными из репозитория

Будем работать с данными с сайта [UC Irvine Machine Learning Repository](#). Посмотрев несколько датасетов было принято решение взять набор данных [Breast Cancer Wisconsin](#), в котором представлены медицинские записи, связанные с эпизодами рака молочной железы. Эта база была получена из Больницы Университета Висконсин, штат Мэдисон от доктора Уильяма Х. Вольберга.

```
Group 1: 367 instances (January 1989)
Group 2: 70 instances (October 1989)
Group 3: 31 instances (February 1990)
Group 4: 17 instances (April 1990)
Group 5: 48 instances (August 1990)
Group 6: 49 instances (Updated January 1991)
Group 7: 31 instances (June 1991)
Group 8: 86 instances (November 1991)
```

```
-----
Total: 699 points (as of the donated database on 15 July 1992)
```

После скачивания и распаковки архива будем использовать данные из файла `breast-cancer-wisconsin.data`, а необходимую справку, в т.ч. подписи к столбцам найдём в файле `breast-cancer-wisconsin.names`.

3.1 Формирование тестовых и обучающих выборок

В указанном файле данные представлены как целочисленные значения, разделённые запятыми со следующими атрибутами:

1. Номер в базе данных
2. Clump Thickness
3. Uniformity of Cell Size
4. Uniformity of Cell Shape
5. Marginal Adhesion
6. Single Epithelial Cell Size
7. Bare Nuclei
8. Bland Chromatin
9. Normal Nucleoli
10. Mitoses
11. Класс новообразования (доброкачественное/злокачественное).

Прочие сведения:

- Все значения кроме первого и последнего столбца представлены целыми числами от 1 до 10;
- Первый столбец (номер в базе) мы отбрасываем как не релевантный, с этого момента будем считать первым столбцом **Clump Thickness**. Последний же столбец это и есть метка класса;
- Из таблицы были удалены 16 объектов, в свойствах которых встречались пропуски;
- Из оставшихся 444 объекта классифицированы как доброкачественные и 239 как злокачественные;
- Для обучения классификатора было случайным образом отобрано около 4/5 из каждого класса: 356 доброкачественных (88 на тест) и 192 злокачественных (47 на тест).

Итого мы имеем дело с задачей классификации 9-мерных данных. Попробуем визуализировать несколько троек признаков в трёхмерной точечной диаграмме:




Рис. 9: Визуализация столбцов 3,5,6. Синий: доброкачественные, красный: злокачественные. На нижнем подграфике тестовые точки наложены поверх оттенённых тренировочных

Поскольку данные выражены целыми числами в фиксированном диапазоне получаем характерный решётчатый паттерн. Несмотря на это отмечаем характерное скопление синих маркеров в одном углу куба. Хотя их больше по количеству, видно, что они занимают меньший диапазон значений, по крайней мере вдоль выбранных осей.




Рис. 10: Визуализация столбцов 1,2,8. Синий: доброкачественные, красный: злокачественные.

Для этой тройки измерений отмечаем аналогичную тенденцию с группировкой доброкачественных значений.

3.2 LDA

Перейдём уже к анализу выбранного датасета.

- Число наблюдений первого класса: $n_1 = 356$
- Число наблюдений второго класса: $n_2 = 192$
- Размерность: $p = 9$
- Выборочное среднее класса 1 :

$$\hat{\mu}^{(1)} = [2.972 \quad 1.303 \quad 1.441 \quad 1.326 \quad 2.138 \quad 1.382 \quad 2.073 \quad 1.267 \quad 1.076]^T$$

- Выборочное среднее класса 2:

$$\hat{\mu}^{(2)} = [7.339 \quad 6.734 \quad 6.635 \quad 5.630 \quad 5.276 \quad 7.505 \quad 5.984 \quad 5.979 \quad 2.635]^T$$

- Выборочная матрица ковариации для класса 1:

$$S_1 = \begin{bmatrix} 2.754 & 0.431 & 0.550 & 0.449 & 0.212 & 0.278 & 0.239 & 0.382 & -0.040 \\ 0.431 & 0.803 & 0.660 & 0.236 & 0.352 & 0.518 & 0.237 & 0.431 & 0.014 \\ 0.550 & 0.660 & 1.030 & 0.236 & 0.328 & 0.459 & 0.171 & 0.386 & -0.003 \\ 0.449 & 0.236 & 0.236 & 0.834 & 0.262 & 0.453 & 0.106 & 0.197 & 0.037 \\ 0.212 & 0.352 & 0.328 & 0.262 & 0.851 & 0.384 & 0.167 & 0.408 & -0.010 \\ 0.278 & 0.518 & 0.459 & 0.453 & 0.384 & 1.594 & 0.302 & 0.348 & 0.075 \\ 0.239 & 0.237 & 0.171 & 0.106 & 0.167 & 0.302 & 1.155 & 0.358 & -0.037 \\ 0.382 & 0.431 & 0.386 & 0.197 & 0.408 & 0.348 & 0.358 & 0.962 & 0.030 \\ -0.040 & 0.014 & -0.003 & 0.037 & -0.010 & 0.075 & -0.037 & 0.030 & 0.318 \end{bmatrix}$$

- Выборочная матрица ковариации для класса 2:

$$S_2 = \begin{bmatrix} 5.733 & 0.829 & 1.124 & -0.942 & 0.477 & 0.325 & -0.094 & -0.433 & 0.941 \\ 0.829 & 7.442 & 5.123 & 2.776 & 3.137 & 0.124 & 2.781 & 2.570 & 1.636 \\ 1.124 & 5.123 & 6.641 & 2.341 & 2.483 & 0.714 & 2.287 & 2.526 & 1.484 \\ -0.942 & 2.776 & 2.341 & 10.297 & 1.469 & 2.193 & 2.858 & 1.819 & 1.875 \\ 0.477 & 3.137 & 2.483 & 1.469 & 5.761 & -0.318 & 1.664 & 1.734 & 1.913 \\ 0.325 & 0.124 & 0.714 & 2.193 & -0.318 & 10.000 & 1.139 & -0.597 & -0.448 \\ -0.094 & 2.781 & 2.287 & 2.858 & 1.664 & 1.139 & 5.555 & 2.356 & 0.376 \\ -0.433 & 2.570 & 2.526 & 1.819 & 1.734 & -0.597 & 2.356 & 11.612 & 2.055 \\ 0.941 & 1.636 & 1.484 & 1.875 & 1.913 & -0.448 & 0.376 & 2.055 & 7.039 \end{bmatrix}$$

- Объединённая матрица ковариации:

$$S = \begin{bmatrix} 3.796 & 0.570 & 0.751 & -0.038 & 0.305 & 0.295 & 0.122 & 0.097 & 0.303 \\ 0.570 & 3.126 & 2.221 & 1.124 & 1.326 & 0.380 & 1.127 & 1.180 & 0.581 \\ 0.751 & 2.221 & 2.993 & 0.972 & 1.082 & 0.548 & 0.911 & 1.135 & 0.518 \\ -0.038 & 1.124 & 0.972 & 4.145 & 0.684 & 1.061 & 1.069 & 0.765 & 0.680 \\ 0.305 & 1.326 & 1.082 & 0.684 & 2.569 & 0.138 & 0.691 & 0.872 & 0.662 \\ 0.295 & 0.380 & 0.548 & 1.061 & 0.138 & 4.535 & 0.594 & 0.018 & -0.108 \\ 0.122 & 1.127 & 0.911 & 1.069 & 0.691 & 0.594 & 2.694 & 1.057 & 0.108 \\ 0.097 & 1.180 & 1.135 & 0.765 & 0.872 & 0.018 & 1.057 & 4.688 & 0.739 \\ 0.303 & 0.581 & 0.518 & 0.680 & 0.662 & -0.108 & 0.108 & 0.739 & 2.669 \end{bmatrix}$$

- Вектор дискриминантной функции:

$$\mathbf{a} = [-0.858 \quad -0.680 \quad -0.319 \quad -0.265 \quad -0.198 \quad -1.076 \quad -0.407 \quad -0.558 \quad -0.033]^T$$

- Расстояние Махаланобиса: $D^2 = 21.724$

- Скорректированное расстояние: $D_H^2 = 21.254$

- Средняя проекция выборки 1-го класса на дискриминантную ось: $\bar{z}^{(1)} = -7.745$

- Средняя проекция выборки 2-го класса на дискриминантную ось: $\bar{z}^{(2)} = -29.469$

- Пороговое значение дискриминатора: $\tau = -19.224$

- Теоретическая вероятность принять 1-й класс за 2-й: $\hat{P}(2|1) = 0.007$

- Теоретическая вероятность принять 2-й класс за 1-й: $\hat{P}(1|2) = 0.015$

- Эмпирическая вероятность принять 1-й класс за 2-й: $\hat{f}(2|1) = 0.020$

- Эмпирическая вероятность принять 2-й класс за 1-й: $\hat{f}(1|2) = 0.078$

- Частота принятия 1-го класса за 2-й на тесте: $f(2|1) = 0.022$

- Частота принятия 2-го класса за 1-й на тесте: $f(1|2) = 0.022$

- Точность классификатора: $\text{Acc} = 0.978$

По результатам линейного дискриминантного анализа оказалось, что данные отлично разделяются в 9-мерном пространстве. Высокое значение расстояния Махаланобиса между классами ($D_H^2 = 21.254$) отразилось на работе классификатора, который показал общую точность в 97.8%. Но сможем ли мы сохранить её после понижения размерности?

4 Построение главных компонент для данных из репозитория

Как быстро стало очевидно после обзора датасетов в репозитории, данные высокой размерности это не редкость, а, напротив, суровая обыденность. Выборочные ковариационные матрицы наших 9-мерных данных, рассматриваемых сейчас, уже неудобно помещать на странице, но они могут в дальнейшем показаться цветочками, поэтому надо быть готовым к понижению размерности, с целью упрощения дальнейшей обработки. Применим к алгоритм анализа главных компонент.

- Вектор выборочных средних: $\bar{\mathbf{x}} = [4.502 \quad 3.206 \quad 3.261 \quad 2.834 \quad 3.237 \quad 3.527 \quad 3.443 \quad 2.918 \quad 1.62]^T$
- Ковариационная матрица: $S = \begin{bmatrix} 8.137 & 5.977 & 5.922 & 4.248 & 3.429 & 6.391 & 4.017 & 4.789 & 1.855 \\ 5.977 & 9.846 & 8.650 & 6.453 & 5.211 & 7.962 & 5.969 & 7.013 & 2.511 \\ 5.922 & 8.650 & 9.140 & 6.069 & 4.797 & 7.800 & 5.542 & 6.714 & 2.364 \\ 4.248 & 6.453 & 6.069 & 8.362 & 3.763 & 7.069 & 4.906 & 5.389 & 2.210 \\ 3.429 & 5.211 & 4.797 & 3.763 & 4.810 & 4.520 & 3.489 & 4.243 & 1.777 \\ 6.391 & 7.962 & 7.800 & 7.069 & 4.520 & 13.076 & 6.055 & 6.597 & 2.070 \\ 4.017 & 5.969 & 5.542 & 4.906 & 3.489 & 6.055 & 6.178 & 5.258 & 1.499 \\ 4.789 & 7.013 & 6.714 & 5.389 & 4.243 & 6.597 & 5.258 & 9.743 & 2.413 \\ 1.855 & 2.511 & 2.364 & 2.210 & 1.777 & 2.070 & 1.499 & 2.413 & 3.219 \end{bmatrix}$
- Собственные значения: $\lambda = [50.387 \quad 5.176 \quad 4.205 \quad 3.355 \quad 2.823 \quad 2.379 \quad 1.814 \quad 1.575 \quad 0.796]^T$
- Общая дисперсия: $\text{Var}_{\text{tot}} = 72.511$
- Объяснённая дисперсия вдоль осей: $\mathbf{Var} = [0.695 \quad 0.071 \quad 0.058 \quad 0.046 \quad 0.039 \quad 0.033 \quad 0.025 \quad 0.022 \quad 0.011]^T$

Особенно стоит обратить внимание на последний пункт с количеством объяснённой дисперсии. Поскольку в силу специфики значений в представленном датасете все точки в нём ограничены гиперкубом со ребром длины 10, наличие одного доминирующего направления, вдоль которого распределено $> 2/3$ (69.5%) дисперсии, выглядит для задачи бинарной классификации многообещающим. Да, из предыдущих экспериментов мы уже знаем, что данные хорошо разделяются, но теперь у нас есть основания надеяться, что подобное получится повторить и после понижения размерности.

Несколько графиков:




Рис. 11: Проекция данных из репозитория на 1 и 2 главные компоненты




Рис. 12: Проекция данных из репозитория на 1 и 3 главные компоненты




Рис. 13: Проекция данных из репозитория на 1 и 5 главные компоненты




Рис. 14: Трёхмерная точечная диаграмма, проецирующая данные на базис $(\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3)$

После визуальной оценки графиков проекций можно заключить, что вдоль первой главной компоненты классы действительно отлично разделяются. Остальные же – объясняют внутриклассовую дисперсию. Соответственно, классификаторы нужно строить по проекциям на базисы, содержащие $\mathbf{v}_1$. Ниже представлено сравнение результативности LDA применительно к подпространствам исходных данных (проекции на базисы, составленные из векторов главных компонент): $\Omega^{(1)}$, $\Omega^{(1,2)}$, $\Omega^{(1,3)}$. В том числе на одномерное подпространство, составленное из проекций на первую главную компоненту.

Название	Обозначение	$\Omega^{(1)}$	$\Omega^{(1,2)}$	$\Omega^{(1,3)}$
Число наблюдений первого класса	n_1	356	356	356
Число наблюдений второго класса	n_2	192	192	192
Размерность	p	1	2	2
Выборочное среднее класса 1	$\hat{\mu}^{(1)}$	[4.715]	$\begin{bmatrix} 4.715 \\ 0.134 \end{bmatrix}$	$\begin{bmatrix} 4.715 \\ 0.078 \end{bmatrix}$
Выборочное среднее класса 2	$\hat{\mu}^{(2)}$	[-8.743]	$\begin{bmatrix} -8.743 \\ -0.249 \end{bmatrix}$	$\begin{bmatrix} -8.743 \\ -0.146 \end{bmatrix}$
Выборочная матрица ковариации класса 1	S_1	[3.601]	$\begin{bmatrix} 3.601 & 0.265 \\ 0.265 & 0.960 \end{bmatrix}$	$\begin{bmatrix} 3.601 & 0.643 \\ 0.643 & 1.750 \end{bmatrix}$
Выборочная матрица ковариации класса 2	S_2	[19.339]	$\begin{bmatrix} 19.339 & -3.862 \\ -3.862 & 12.942 \end{bmatrix}$	$\begin{bmatrix} 19.339 & -3.165 \\ -3.165 & 8.758 \end{bmatrix}$
Объединённая матрица ковариации	S	[9.106]	$\begin{bmatrix} 9.106 & -1.179 \\ -1.179 & 5.152 \end{bmatrix}$	$\begin{bmatrix} 9.106 & -0.689 \\ -0.689 & 4.202 \end{bmatrix}$
Вектор дискриминантной функции	$\mathbf{a}$	[1.478]	[1.533, 0.425]	[1.500, 0.299]
Расстояние Махаланобиса	D^2	19.888	20.792	20.260
Скорректированное расстояние	D_H^2	19.808	20.662	20.133
Ср. проекция выборки 1 кл. на ось	$\bar{z}^{(1)}$	6.968	7.285	7.098
Ср. проекция выборки 2 кл. на ось	$\bar{z}^{(2)}$	-12.920	-13.507	-13.162
Пороговое значение дискриминатора	τ	-3.593	-3.729	-3.649
Теор. вер-сть принять 1-й класс за 2-й	$\hat{P}(2 1)$	0.009	0.008	0.008
Теор. вер-сть принять 2-й класс за 1-й	$\hat{P}(1 2)$	0.018	0.016	0.018
Эмпир. вер-сть принять 1-й класс за 2-й	$\hat{f}(2 1)$	0.022	0.020	0.025
Эмпир. вер-сть принять 2-й класс за 1-й	$\hat{f}(1 2)$	0.073	0.083	0.068
Частота принятия 1-го класса за 2-й на тесте	$f(2 1)$	0.011	0.022	0.000
Частота принятия 2-го класса за 1-й на тесте	$f(1 2)$	0.021	0.022	0.021
Точность классификатора	Acc	0.985	0.978	0.993

Как видим, наши данные оказались прекрасно разделимы даже в одномерном случае. Более того, достигнутая таким образом точность превысила точность исходного LDA ($98.5\% > 97.8\%$). То есть добавление дополнительных размерностей подпространства оказывает нелинейное влияние на характеристики классификатора. Так, для $\Omega^{(1,2)}$ точность составила 97.8%, повторив результат исходного LDA, а вот $\Omega^{(1,3)}$ позволила достичь классификатору точности в 99.3%. Заметим, что линейной зависимости между расстоянием Махаланобиса и точностью классификатора также не прослеживается. В таблице ниже Ω относится к результатам LDA по всем измерениям (до PCA):

Название	Обозначение	Ω	$\Omega^{(1)}$	$\Omega^{(1,2)}$	$\Omega^{(1,3)}$
Скорректированное расстояние Махаланобиса	D_H^2	21.254	19.808	20.662	20.133
Точность классификатора	Acc	0.978	0.985	0.978	0.993

Тем не менее, полученные результаты нельзя считать окончательными: для экспериментов с данными из репозитория тестовые выборки были предварительно зафиксированы. Перебор объектов тестовых выборок мог бы послужить основой более надёжных результатов, что выходит за рамки этой работы.

5 Подведение итогов

В данной работе было продемонстрирован способ бинарной классификации основанный на линейном дискриминантном анализе (LDA) в том числе со снижением размерности с использованием метода главных компонент (PCA). Использовались как трёхмерные модельные данные, так и 9-мерные медицинские данные из репозитория. Были даны теоретические (с использованием рассчитанных расстояний Махаланобиса) и эмпирические оценки ошибок классификации. Было показано, что в некоторых случаях снижение размерности может не только снизить вычислительную сложность задачи обработки данных, но и, в некоторых случаях, даже повысить точность классификации (впрочем, в случае плохо разделимых модельных данных точность классификатора при снижении размерности понижалась).