

Работа допущена к защите
Руководитель ОП

«_____» _____ 202_ г.

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
РАБОТА БАКАЛАВРА
РАЗРАБОТКА ПРОГРАММНОГО ОБЕСПЕЧЕНИЯ ДЛЯ АНАЛИЗА
ПОЧВЕННОЙ МИКРОБИОТЫ С ИСПОЛЬЗОВАНИЕМ СИСТЕМ
ВЫСОКОПРОИЗВОДИТЕЛЬНОГО СЕКВЕНИРОВАНИЯ
по направлению подготовки 01.03.02 Прикладная математика и информатика
Направленность (профиль) 01.03.02_04 Биоинформатика

Выполнил

студент гр. 5030102/20401

А.Д. Безлепский

Руководитель

доцент,

кандидат ф.-м. наук,

В.В. Гурский

Консультант

д.б.н., г.н.с.

Е.Е. Андронов

Консультант

по нормоконтролю

Л.А. Арефьева

Санкт-Петербург

2026

Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
ФизМех

УТВЕРЖДАЮ

Руководитель ОП

«_____» _____ 202_г.

ЗАДАНИЕ
на выполнение выпускной квалификационной работы

студенту Безлепскому Александру Дмитриевичу, гр. 5030102/20401

1. Тема работы: «Разработка программного обеспечения для анализа почвенной микро
2. Срок сдачи студентом законченной работы: 27.05.2026.
3. Исходные данные по работе: нуклеотидные последовательности генов ризобий из базы данных GenBank и коллекции лаборатории [3.2]; параметры термодинамических моделей ближайших соседей [3.3]; сырые данные ампликонного секвенирования (Illumina MiSeq); программная среда Julia и язык R [3.1].
 - 3.1. DADA2: High-resolution sample inference from Illumina amplicon data / B. J. Callahan [и др.] // Nature Methods. — 2016. — Т. 13, № 7. — С. 581—583. — DOI 10.1038/nmeth.3869. — URL: <https://doi.org/10.1038/nmeth.3869>.
 - 3.2. Pangenome Evolution Reconciles Robustness and Instability of Rhizobial Symbiosis / A. J. Weisberg [и др.] // mBio. — 2022. — Т. 13, № 3. — e00074—22. — DOI 10.1128/mbio.00074-22. — eprint: <https://journals.asm.org/doi/pdf/10.1128/mbio.00074-22>. — URL: <https://journals.asm.org/doi/abs/10.1128/mbio.00074-22>.
 - 3.3. *SantaLucia J. J., Hicks D.* The Thermodynamics of DNA Structural Motifs // Annual Review of Biophysics. — 2004. — Т. 33. — С. 415—440. — DOI 10.1146/annurev.biophys.32.110601.141800. — URL: <https://doi.org/10.1146/annurev.biophys.32.110601.141800>.
4. Содержание работы (перечень подлежащих разработке вопросов):

- 4.1. Обзор литературы: проблема анализа почвенной микробиоты и вычислительные аспекты дизайна ПЦР-праймеров.
- 4.2. Разработка математических моделей и алгоритмов конструирования выроденных ПЦР-праймеров с учетом ансамблевой термодинамики.
- 4.3. Разработка и оптимизация программного обеспечения для термодинамического анализа на языке Julia.
- 4.4. Апробация алгоритмов и анализ данных высокопроизводительного секвенирования популяций ризобий.
5. Перечень графического материала:
 - 5.1. Архитектура и диаграмма классов разработанных пакетов SeqFold.jl и DePPA.jl.
 - 5.2. Результаты сравнения производительности вычислительного ядра SeqFold.jl с программными аналогами.
 - 5.3. Результаты агарозного электрофореза продуктов вложенной ПЦР при амплификации целевых генов.
 - 5.4. Лист подготовки проб составленный перед секвенированием Illumina MiSeq
 - 5.5. Диаграммы Венна и фактор обогащения уникальными ASV для исследованных групп генов.
6. Перечень используемых информационных технологий, в том числе программное обеспечение, облачные сервисы, базы данных и прочие сквозные цифровые технологии:
 - 6.1. Язык программирования Julia, пакеты SeqFold.jl, DePPA.jl, FastaIO.jl.
 - 6.2. Язык программирования R, пакеты DADA2, phyloseq, ggplot2, dyplr, tidyr.
 - 6.3. Система контроля версий Git и платформы GitHub и GitLab.
 - 6.4. База данных нуклеотидных последовательностей NCBI GenBank и инструмент поиска гомологий BLAST.
 - 6.5. Научные электронные библиотеки и репозитории (ncbi.nlm.nih.gov, arxiv.org, bioRxiv.org, geneontology.org).
7. Консультанты по работе:
 - 7.1. Д.б.н., г.н.с., Е.Е. Андронов.
 - 7.2. Должность, степень, Л.А. Арефьева (нормоконтроль).
8. Дата выдачи задания: 27.05.2026.

Руководитель ВКР _____ В.В. Гурский

Консультант _____ Е.Е. Андронов

Задание принял к исполнению 27.05.2026

Студент _____ А.Д. Безлепский

РЕФЕРАТ

На 67 с., 16 рис., 4 табл., 2 прил.

Ключевые слова: высокопроизводительное секвенирование, вырожденные ПЦР-праймеры, ансамблевая термодинамика, почвенная микробиота, ризобии Тема выпускной квалификационной работы — разработка программного обеспечения для анализа почвенной микробиоты методами высокопроизводительного секвенирования. Цель работы — создание высокопроизводительного ПО на языке Julia для конструирования вырожденных ПЦР-праймеров с учетом ансамблевой термодинамики и его апробация на популяциях клубеньковых бактерий. Объект исследования — процессы биоинформатического анализа данных секвенирования. Предмет — алгоритмы расчета статистических распределений термодинамических параметров для пулов вырожденных олигонуклеотидов. Методология исследования опирается на модель термодинамики ближайших соседей, алгоритмы динамического программирования предсказания вторичной структуры и вероятностный денойзинг данных. В результате работы портировано и оптимизировано вычислительное ядро SeqFold.jl, спроектирован и реализован пакет DePPA.jl. Сконструированы и лабораторно валидированы наборы праймеров для шести генов ризобий. Подготовлены и успешно секвенированы 36 ампликонных библиотек. Биоинформатический анализ подтвердил биологическую гипотезу: свободноживущие почвенные популяции формируют обширный резервуар уникальных аллелей симбиотических генов, который при формировании симбиоза проходит через строгий экологический фильтр растения-хозяина. Область применения результатов — биоинформатика, молекулярная экология и микробиология. Разработанные инструменты позволяют существенно минимизировать ПЦР-смещения при таргетном анализе сложных микробных сообществ.

ABSTRACT

On 67 pages, 16 figures, 4 tables, 2 appendices

Keywords: high-throughput sequencing, degenerate PCR primers, ensemble thermodynamics, soil microbiota, rhizobia

The subject of the graduate qualification work is «Development of Software for Soil Microbiota Analysis Using High-Throughput Sequencing Systems».

The subject of the graduate qualification work is the development of software for soil microbiota analysis using high-throughput sequencing systems. The goal is to create high-performance software in Julia for designing degenerate PCR primers considering ensemble thermodynamics and its testing on rhizobia populations. The object of the research is the processes of bioinformatic analysis of sequencing data. The subject is the algorithms for calculating statistical distributions of thermodynamic parameters for pools of degenerate oligonucleotides. The methodology is based on the nearest-neighbor thermodynamic model, dynamic programming algorithms for secondary structure prediction, and probabilistic data denoising. As a result, the SeqFold.jl computational core was ported and optimized, and the DePPA.jl package was designed and implemented. Primer sets for six rhizobia genes were designed and laboratory validated. 36 amplicon libraries were prepared and successfully sequenced. Bioinformatic analysis confirmed the biological hypothesis: free-living soil populations form an extensive reservoir of unique alleles of symbiotic genes, which passes through a strict ecological filter of the host plant during symbiosis formation. The application area is bioinformatics, molecular ecology, and microbiology. The developed tools allow minimizing PCR biases in the targeted analysis of complex microbial communities.

The subject of the graduate qualification work is the development of software for soil microbiota analysis using high-throughput sequencing systems. The goal is to create high-performance software in Julia for designing degenerate PCR primers considering ensemble thermodynamics and its testing on rhizobia populations. The object of the research is the processes of bioinformatic analysis of sequencing data. The subject is the algorithms for calculating statistical distributions of thermodynamic parameters for pools of degenerate oligonucleotides. The methodology is based on the nearest-neighbor thermodynamic model, dynamic programming algorithms for secondary structure prediction, and probabilistic data denoising. As a result, the SeqFold.jl computational core was ported and optimized, and the DePPA.jl package was designed and implemented. Primer sets for six rhizobia genes were designed and laboratory validated. 36 amplicon libraries were prepared and successfully sequenced. Bioinformatic analysis confirmed the biological hypothesis: free-living soil populations form an extensive reservoir of unique alleles of symbiotic genes, which passes through a strict ecological filter of the host plant during symbiosis formation. The application area is bioinformatics, molecular ecology, and microbiology. The developed tools allow minimizing PCR biases in the targeted analysis of complex microbial communities.