

Работа допущена к защите
Руководитель ОП

«_____» _____ 202_ г.

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
РАБОТА БАКАЛАВРА
РАЗРАБОТКА ПРОГРАММНОГО ОБЕСПЕЧЕНИЯ ДЛЯ АНАЛИЗА
ПОЧВЕННОЙ МИКРОБИОТЫ С ИСПОЛЬЗОВАНИЕМ СИСТЕМ
ВЫСОКОПРОИЗВОДИТЕЛЬНОГО СЕКВЕНИРОВАНИЯ
по направлению подготовки 01.03.02 Прикладная математика и информатика
Направленность (профиль) 01.03.02_04 Биоинформатика

Выполнил
студент гр. 5030102/20401

А.Д. Безлепский

Руководитель
доцент,
кандидат ф.-м. наук,

В.В. Гурский

Консультант
д.б.н., г.н.с.

Е.Е. Андронов

Консультант
по нормоконтролю

Л.А. Арефьева

Санкт-Петербург
2026

Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
ФизМех

УТВЕРЖДАЮ

Руководитель ОП

«_____» _____ 202_г.

ЗАДАНИЕ
на выполнение выпускной квалификационной работы

студенту Безлепскому Александру Дмитриевичу, гр. 5030102/20401

1. Тема работы: «Разработка программного обеспечения для анализа почвенной микрофлоры»
2. Срок сдачи студентом законченной работы: 27.05.2026.
3. Исходные данные по работе: нуклеотидные последовательности генов ризобий из базы данных GenBank и коллекции лаборатории [3.2]; параметры термодинамических моделей ближайших соседей [3.3]; сырые данные ампликонного секвенирования (Illumina MiSeq); программная среда Julia и язык R [3.1].
 - 3.1. DADA2: High-resolution sample inference from Illumina amplicon data / B. J. Callahan [и др.] // Nature Methods. — 2016. — Т. 13, № 7. — С. 581—583. — DOI 10.1038/nmeth.3869. — URL: <https://doi.org/10.1038/nmeth.3869>.
 - 3.2. Pangenome Evolution Reconciles Robustness and Instability of Rhizobial Symbiosis / A. J. Weisberg [и др.] // mBio. — 2022. — Т. 13, № 3. — e00074—22. — DOI 10.1128/mbio.00074-22. — eprint: <https://journals.asm.org/doi/pdf/10.1128/mbio.00074-22>. — URL: <https://journals.asm.org/doi/abs/10.1128/mbio.00074-22>.
 - 3.3. *SantaLucia J. J., Hicks D.* The Thermodynamics of DNA Structural Motifs // Annual Review of Biophysics. — 2004. — Т. 33. — С. 415—440. — DOI 10.1146/annurev.biophys.32.110601.141800. — URL: <https://doi.org/10.1146/annurev.biophys.32.110601.141800>.
4. Содержание работы (перечень подлежащих разработке вопросов):

- 4.1. Обзор литературы: проблема анализа почвенной микробиоты и вычислительные аспекты дизайна ПЦР-праймеров.
- 4.2. Разработка математических моделей и алгоритмов конструирования выродженных ПЦР-праймеров с учетом ансамблевой термодинамики.
- 4.3. Разработка и оптимизация программного обеспечения для термодинамического анализа на языке Julia.
- 4.4. Апробация алгоритмов и анализ данных высокопроизводительного секвенирования популяций ризобий.
5. Перечень графического материала:
 - 5.1. Архитектура и диаграмма классов разработанных пакетов SeqFold.jl и DePPA.jl.
 - 5.2. Результаты сравнения производительности вычислительного ядра SeqFold.jl с программными аналогами.
 - 5.3. Результаты агарозного электрофореза продуктов вложенной ПЦР при амплификации целевых генов.
 - 5.4. Лист подготовки проб составленный перед секвенированием Illumina MiSeq
 - 5.5. Диаграммы Венна и фактор обогащения уникальными ASV для исследованных групп генов.
6. Перечень используемых информационных технологий, в том числе программное обеспечение, облачные сервисы, базы данных и прочие сквозные цифровые технологии:
 - 6.1. Язык программирования Julia, пакеты SeqFold.jl, DePPA.jl, FastaIO.jl.
 - 6.2. Язык программирования R, пакеты DADA2, phyloseq, ggplot2, dyplr, tidyr.
 - 6.3. Система контроля версий Git и платформы GitHub и GitLab.
 - 6.4. База данных нуклеотидных последовательностей NCBI GenBank и инструмент поиска гомологий BLAST.
 - 6.5. Научные электронные библиотеки и репозитории (ncbi.nlm.nih.gov, arxiv.org, bioRxiv.org, geneontology.org).
7. Консультанты по работе:
 - 7.1. Д.б.н., г.н.с., Е.Е. Андронов.
 - 7.2. Должность, степень, Л.А. Арефьева (нормоконтроль).
8. Дата выдачи задания: 27.05.2026.

Руководитель ВКР _____ В.В. Гурский

Консультант _____ Е.Е. Андронов

Задание принял к исполнению 27.05.2026

Студент _____ А.Д. Безлепский

РЕФЕРАТ

На 67 с., 16 рис., 4 табл., 2 прил.

Ключевые слова: высокопроизводительное секвенирование, вырожденные ПЦР-праймеры, ансамблевая термодинамика, почвенная микробиота, ризобии

Тема выпускной квалификационной работы — разработка программного обеспечения для анализа почвенной микробиоты методами высокопроизводительного секвенирования. Цель работы — создание высокопроизводительного ПО на языке Julia для конструирования вырожденных ПЦР-праймеров с учетом ансамблевой термодинамики и его апробация на популяциях клубеньковых бактерий. Объект исследования — процессы биоинформатического анализа данных секвенирования. Предмет — алгоритмы расчета статистических распределений термодинамических параметров для пулов вырожденных олигонуклеотидов. Методология исследования опирается на модель термодинамики ближайших соседей, алгоритмы динамического программирования предсказания вторичной структуры и вероятностный денойзинг данных. В результате работы портировано и оптимизировано вычислительное ядро SeqFold.jl, спроектирован и реализован пакет DePPA.jl. Сконструированы и лабораторно валидированы наборы праймеров для шести генов ризобий. Подготовлены и успешно секвенированы 36 ампликонных библиотек. Биоинформатический анализ подтвердил биологическую гипотезу: свободноживущие почвенные популяции формируют обширный резервуар уникальных аллелей симбиотических генов, который при формировании симбиоза проходит через строгий экологический фильтр растения-хозяина. Область применения результатов — биоинформатика, молекулярная экология и микробиология. Разработанные инструменты позволяют существенно минимизировать ПЦР-смещения при таргетном анализе сложных микробных сообществ.

ABSTRACT

On 67 pages, 16 figures, 4 tables, 2 appendices

Keywords: high-throughput sequencing, degenerate PCR primers, ensemble thermodynamics, soil microbiota, rhizobia

The subject of the graduate qualification work is «Development of Software for Soil Microbiota Analysis Using High-Throughput Sequencing Systems».

The subject of the graduate qualification work is the development of software for soil microbiota analysis using high-throughput sequencing systems. The goal is to create high-performance software in Julia for designing degenerate PCR primers considering ensemble thermodynamics and its testing on rhizobia populations. The object of the research is the processes of bioinformatic analysis of sequencing data. The subject is the algorithms for calculating statistical distributions of thermodynamic parameters for pools of degenerate oligonucleotides. The methodology is based on the nearest-neighbor thermodynamic model, dynamic programming algorithms for secondary structure prediction, and probabilistic data denoising. As a result, the SeqFold.jl computational core was ported and optimized, and the DePPA.jl package was designed and implemented. Primer sets for six rhizobia genes were designed and laboratory validated. 36 amplicon libraries were prepared and successfully sequenced. Bioinformatic analysis confirmed the biological hypothesis: free-living soil populations form an extensive reservoir of unique alleles of symbiotic genes, which passes through a strict ecological filter of the host plant during symbiosis formation. The application area is bioinformatics, molecular ecology, and microbiology. The developed tools allow minimizing PCR biases in the targeted analysis of complex microbial communities.

The subject of the graduate qualification work is the development of software for soil microbiota analysis using high-throughput sequencing systems. The goal is to create high-performance software in Julia for designing degenerate PCR primers considering ensemble thermodynamics and its testing on rhizobia populations. The object of the research is the processes of bioinformatic analysis of sequencing data. The subject is the algorithms for calculating statistical distributions of thermodynamic parameters for pools of degenerate oligonucleotides. The methodology is based on the nearest-neighbor thermodynamic model, dynamic programming algorithms for secondary structure prediction, and probabilistic data denoising. As a result, the SeqFold.jl computational core was ported and optimized, and the DePPA.jl package was designed and implemented. Primer sets for six rhizobia genes were designed and laboratory validated. 36 amplicon libraries were prepared and successfully sequenced. Bioinformatic analysis confirmed the biological hypothesis: free-living soil populations form an extensive reservoir of unique alleles of symbiotic genes, which passes through a strict ecological filter of the host plant during symbiosis formation. The application area is bioinformatics, molecular ecology, and microbiology. The developed tools allow minimizing PCR biases in the targeted analysis of complex microbial communities.

СОДЕРЖАНИЕ

Введение	9
Глава 1 Обзор литературы: Проблема анализа популяций ризобий и вычислительные аспекты дизайна ПЦР-праймеров.....	12
1.1 Биология ризобий и проблема «некультивируемого» разнообразия. Симбиотические и свободноживущие популяции. Ограничения классической микробиологии	13
1.2 Высокопроизводительное секвенирование ампликонов. Специфика работы с почвой и необходимость вложенной ПЦР	14
1.3 Математические модели термодинамики нуклеиновых кислот. Модели SantaLucia и Zuker. Проблема расчета параметров для вырожденных (IUPAC) последовательностей	16
1.4 Анализ существующего программного обеспечения. Обоснование неприменимости классических инструментов для ансамблевой термодинамики	19
1.5 Выводы по главе 1	21
Глава 2 Математические модели и алгоритмы конструирования вырожденных ПЦР-праймеров	22
2.1 Формализация задачи дизайна праймеров на основе множественного выравнивания	22
2.2 Алгоритм расчета ансамблевой термодинамики для пулов олигонуклеотидов	25
2.3 Выводы по главе 2	31
Глава 3 Разработка и оптимизация программного обеспечения для термодинамического анализа.....	32
3.1 Архитектура, верификация и инфраструктура вычислительного ядра SeqFold.jl	32
3.2 Архитектура и программная реализация пакета DePPA.jl	36
3.3 Выводы по главе 3	41
Глава 4 Апробация алгоритмов и анализ данных высокопроизводительного секвенирования.....	41
4.1 In silico конструирование и лабораторная валидация наборов праймеров	42
4.2 Алгоритмы биоинформатической фильтрации и денойзинга данных секвенирования	48
4.3 Сравнительный анализ генетического разнообразия и проверка биологической гипотезы	52
4.4 Выводы по главе 4	58
Заключение	60
Список использованных источников.....	63

Приложение 1 Лист подготовки проб	68
Приложение 2 Результаты анализа бета-разнообразия.....	69

ВВЕДЕНИЕ

Почвенная микробиота играет ключевую роль в биогеохимических циклах, среди которых особое место занимает процесс биологической азотфиксации. Клубеньковые бактерии (ризобии), вступающие в симбиоз с бобовыми растениями, являются одними из главных агентов этого процесса. Традиционно изучение таких микроорганизмов опиралось на классические методы микробиологии, однако значительная часть почвенного разнообразия остается труднодоступной для прямого наблюдения и выделения в чистые культуры [37]. Развитие методов высокопроизводительного секвенирования (HTS) позволило преодолеть эти ограничения [22], однако анализ почвенных образцов, характеризующихся экстремально низкой концентрацией ДНК ризобий и высокой генетической вариабельностью исследуемых генов, сталкивается с рядом серьезных методологических и вычислительных проблем.

Актуальность исследования. Изучение свободноживущих почвенных популяций ризобий требует применения HTS, поскольку классическое культивирование обладает селективным смещением при культивировании (cultivation bias) [37]. Экстремально низкая концентрация целевой ДНК в почве и высокая вариабельность симбиотических генов, локализованных на мобильных генетических элементах [24], диктуют необходимость применения вложенной ПЦР и сильно вырожденных праймеров. Однако использование таких праймеров сопряжено с риском ПЦР-смещения (primer bias) [20; 21]. Существующие биоинформатические инструменты [10; 15] игнорируют физико-химическую гетерогенность пулов вырожденных олигонуклеотидов, оценивая их по усредненным консенсусам или комбинаторным моделям несовпадений. Это приводит к неспецифической амплификации, подавлению редких таксонов и искажению реальной картины микробного разнообразия. Таким образом, разработка высокопроизводительного программного обеспечения, учитывающего ансамблевую термодинамику вырожденных последовательностей, является актуальной научно-технической задачей.

Объект исследования — процессы биоинформатического анализа данных высокопроизводительного секвенирования и математического моделирования физико-химических параметров нуклеиновых кислот.

Предмет исследования — алгоритмы расчета статистических распределений термодинамических характеристик для пулов вырожденных олигонуклеотидов и архитектура программного обеспечения для их реализации.

Цель исследования — разработать высокопроизводительное программное обеспечение на языке Julia для конструирования вырожденных ПЦР-праймеров с учетом ансамблевой термодинамики и апробировать его в рамках полного цикла биоинформатического анализа популяций ризобий, извлеченных из двух контрастных субстратов: почвы (свободноживущие формы) и корневых клубеньков (активный симбиоз).

Гипотезы исследования.

- *Вычислительная:* Учет статистических распределений термодинамических параметров (T_m , ΔG) для всего пула вырожденных праймеров, а не расчет для усредненной консенсусной последовательности, позволяет минимизировать ПЦР-смещение и обеспечивает более репрезентативную амплификацию редких таксонов [35].
- *Биологическая:* Свободноживущие популяции ризобий в почве формируют обширный резервуар уникальных аллелей, который при формировании симбиоза проходит через строгий «экологический фильтр» растения-хозяина, приводящий к существенно большей потере уникального разнообразия симбиотических генов по сравнению с консервативными генами домашнего хозяйства [24].

В соответствии с целью исследования и сформулированными гипотезами, определяются следующие **задачи работы**:

- А. Изучить математические модели термодинамики нуклеиновых кислот и провести сравнительный анализ существующего программного обеспечения для дизайна праймеров [10; 15], выявив ограничения при работе с вырожденными последовательностями.
- В. Разработать алгоритм оценки статистического распределения термодинамических параметров для смесей вырожденных олигонуклеотидов, опираясь на модель ближайших соседей [35] и алгоритмы динамического программирования [43], а также сформулировать математические критерии фильтрации кандидатов для минимизации ПЦР-смещений.
- С. Осуществить программную реализацию разработанных алгоритмов в виде пакетов SeqFold.jl [2] и DePPA.jl [1] на языке Julia [13], обеспечив поддержку IUPAC-кодов и интеграцию с существующими биоинформатическими пайплайнами.
- Д. Провести апробацию разработанного ПО: сконструировать праймеры для 36 библиотек ампликонного секвенирования симбиотических ге-

нов и генов «домашнего хозяйства», осуществить амплификацию и секвенирование, обработать данные алгоритмом DADA2 [5] и провести сравнительный анализ структуры генетического разнообразия для проверки биологической гипотезы.

Теоретическая и методологическая база исследования. Теоретической основой работы послужили фундаментальные исследования в области биофизики нуклеиновых кислот, в частности модели термодинамики ближайших соседей (Nearest-Neighbor) [35] и алгоритмы динамического программирования для предсказания вторичной структуры [43]. Практическая часть работы выполнялась на основе современных подходов к обработке данных ампликонного секвенирования, включая вероятностные модели денойзинга (DADA2) [5] и оценки альфа- и бета-разнообразия микробных сообществ.

Степень научной разработанности проблемы. Биологические аспекты симбиоза ризобий изучены достаточно глубоко [24; 30], однако биоинформатическое обеспечение для таргетного анализа их высоковариабельных генов в сложных почвенных образцах развито слабо. Существующие инструменты были разработаны преимущественно для работы с индивидуальными последовательностями или используют комбинаторные модели несовпадений [10; 15], не принимая во внимание биофизику смесей вырожденных олигонуклеотидов. Проблема математической формализации и программной реализации статистических распределений термодинамических параметров для IUPAC-последовательностей остается недостаточно разработанной, что обуславливает новизну данной работы.

Практическая значимость работы заключается в создании программного продукта с открытым исходным кодом. Разработанные пакеты SeqFold.jl и DePPA.jl могут быть использованы исследователями для дизайна праймеров под любые семейства генов. Кроме того, в ходе работы был получен новый массив биологических данных о структуре почвенных популяций ризобий, а также сконструированы и экспериментально подтверждены новые наборы праймеров с адаптерами для секвенирования на платформе Illumina MiSeq.

Теоретическая значимость работы отражается в развитии методов вычислительной биологии, а именно: в математической формализации задачи дизайна вырожденных праймеров с использованием аппарата ансамблевой термодинамики и разработке алгоритмического подхода к оценке статистических распределений свободной энергии и температуры плавления для смесей олигонуклеотидов.

Апробация результатов исследования. Разработанное программное обеспечение опубликовано в открытых репозиториях и доступно для использования научным сообществом [1; 2]. Сконструированные *in silico* праймеры были успешно валидированы в лабораторных условиях. Полученные данные секвенирования 36 библиотек успешно обработаны и проанализированы. Основные положения работы доложены на научных семинарах кафедры.

Структура работы. Выпускная квалификационная работа изложена на N страницах, состоит из введения, четырех глав, заключения и списка использованных источников. Целью первой главы является анализ предметной области, математических моделей термодинамики и обзор существующих программных решений. Вторая глава посвящена разработке алгоритмов конструирования вырожденных праймеров с учётом ансамблевых термодинамических факторов. В третьей главе описана архитектура и программная реализация разработанных пакетов SeqFold.jl и DePPA.jl. Четвертая глава содержит апробацию разработанного ПО: от лабораторного синтеза праймеров до биоинформатической обработки данных секвенирования и проверки биологической гипотезы.

ГЛАВА 1 ОБЗОР ЛИТЕРАТУРЫ: ПРОБЛЕМА АНАЛИЗА ПОПУЛЯЦИЙ РИЗОБИЙ И ВЫЧИСЛИТЕЛЬНЫЕ АСПЕКТЫ ДИЗАЙНА ПЦР-ПРАЙМЕРОВ

Целью данной главы является комплексное теоретическое и методологическое обоснование необходимости разработки нового вычислительного инструментария для анализа популяций ризобий методами высокопроизводительного секвенирования. В главе проводится критический анализ современных подходов к изучению микробных сообществ, выявляются фундаментальные ограничения классической микробиологии и стандартных протоколов ампликонного секвенирования при работе со сложными почвенными образцами.

Особое внимание уделяется математическому аппарату термодинамики нуклеиновых кислот и строгому анализу существующего биоинформатического программного обеспечения. Как будет показано далее, современные инструменты дизайна праймеров не учитывают физико-химическую гетерогенность пулов вырожденных олигонуклеотидов, что приводит к неустраняемым ПЦР-смещениям и искажению реальной картины микробного разнообразия. Решение этой проблемы

требует перехода от комбинаторных моделей к расчету ансамблевых статистик, что и формирует научный задел для разработки архитектуры пакетов SeqFold.jl и DePPA.jl.

1.1 Биология ризобий и проблема «некультивируемого» разнообразия. Симбиотические и свободноживущие популяции. Ограничения классической микробиологии

Почвенная микробиота представляет собой одну из самых сложных и многообразных экологических систем на планете, играющую ключевую роль в биогеохимических циклах, в частности, в процессе фиксации атмосферного азота [22]. Важнейшими агентами этого процесса являются клубеньковые бактерии (ризобии), которые способны вступать в мутуалистический симбиоз с растениями семейства бобовые (Fabaceae, или Leguminosae), такими как клевер, козлятник и люцерна. Экологические стратегии ризобий характеризуются выраженной двойственностью: они существуют как в форме свободноживущих популяций в почве (ризосфере), так и в форме специализированных симбиотических популяций, формирующих клубеньки на корнях растений [24].

Переход между этими состояниями и поддержание симбиоза обеспечиваются сложной генетической архитектурой. Как показано в работе [24], гены, отвечающие за симбиотическую азотфиксацию (группы *nod*, *nif*, *fix*), не являются жестко закрепленными в ядровом геноме (core genome), который ограничен генами домашнего хозяйства (housekeeping genes). Они чаще всего кластеризованы на мобильных генетических элементах — симбиотических интегрирующихся конъюгативных элементах (symICE) и мегаплазмидах. Высокая модульность и способность к горизонтальному переносу этих элементов приводят к постоянной «перетасовке» генов, что формирует открытый пангеном, обеспечивающий высокое функциональное и генетическое разнообразие, и делает отдельные симбиотические партнерства эволюционно нестабильными, сохраняя при этом общую устойчивость системы.

Даже для тех ризобий, которые удастся культивировать, традиционные методы таксономии оказываются несостоятельными. Долгое время классификация строилась на фенотипических признаках (круг растений-хозяев), методах ДНК-ДНК гибридизации или анализе единственного гена 16S рРНК. Однако этот ген обладает недостаточным разрешением для разделения близких видов и часто искажается из-за горизонтального переноса генов. В работе [30] на основе

мультилокусного анализа последовательностей (MLSA) housekeeping-генов было доказано, что род *Rhizobium* является полифилетичным, а многие исторически сложившиеся таксономические группы требуют пересмотра. Это подтверждает, что фенотип и единичные маркеры не отражают истинной эволюционной истории и функционального потенциала почвенных симбионтов.

Таким образом, для адекватного описания популяций ризобий классические культур-зависимые методы необходимо существенно дополнять прямым анализом экологической ДНК (eDNA). Высокопроизводительное секвенирование (HTS) позволяет преодолеть барьер некультивируемости, однако работа с гетерогенными почвенными образцами и высоковариабельными генами (как симбиотическими, так и хромосомными) требует применения сложных методов ампликонного анализа, которые рассматриваются в следующем параграфе.

1.2 Высокопроизводительное секвенирование ампликонов. Специфика работы с почвой и необходимость вложенной ПЦР

Переход от культурально-зависимых методов к технологиям высокопроизводительного секвенирования (HTS) в корне изменил подходы к изучению микробиома почвы. На сегодняшний день доминирующим методом таксономического и функционального профилирования является ампликонное секвенирование, при котором с помощью полимеразной цепной реакции (ПЦР) амплифицируются целевые маркерные гены (например, 16S рРНК для бактерий, ITS для грибов или функциональные гены, такие как *nifH*, *nodA* или *rpoB*) с последующим секвенированием ампликонов на платформах второго поколения (Illumina) [22]. В отличие от полногеномного shotgun-секвенирования, ампликонный подход требует значительно меньших вычислительных мощностей и финансовых затрат, что делает его оптимальным для анализа больших серий экологических проб [22].

Несмотря на высокую информативность, анализ популяций ризобий в почве сталкивается с рядом уникальных методологических проблем. Почва является одним из наиболее сложных экологических субстратов: она характеризуется экстремально высоким микробным разнообразием, наличием внеклеточной ДНК, а также высоким содержанием гуминовых и фульвокислот, которые выступают мощными ингибиторами ДНК-полимераз [22]. Кроме того, при таргетном анализе специфических групп микроорганизмов, таких как симбиотические ризобии, концентрация целевой ДНК может быть недостаточной на фоне тотального пре-

обладания ДНК других почвенных бактерий и эукариот [8; 24]. Во многом это обусловлено «аномалией подсчета на чашках» (Great Plate Count Anomaly) [37], согласно формулировке которой подавляющее большинство почвенных микроорганизмов не поддается культивированию стандартными методами и существует в виде труднодоступных для выделения форм, что еще больше снижает долю легкоамплифицируемой целевой ДНК в общем пуле.

В условиях низкой концентрации целевой ДНК и наличия ингибиторов стандартная одностадийная ПЦР с прямыми адаптерами для Illumina зачастую оказывается неэффективной и не дает продукта, пригодного для секвенирования. Традиционным решением этой проблемы в молекулярной экологии стало использование вложенной (nested) ПЦР. Этот подход предполагает два последовательных раунда амплификации: первый раунд проводится с неспецифичными или частично специфичными праймерами для накопления целевого продукта, а второй раунд — с праймерами, содержащими полные Illumina-адаптеры и индексные последовательности [21].

Однако применение вложенного ПЦР сопряжено с серьезными методологическими рисками. Работа Yu et al. (2015) [20] продемонстрировала, что два последовательных раунда амплификации многократно усиливают эффект ПЦР-смещения. Авторы показали, что вложенный ПЦР приводит к искажениям оценок альфа- и бета-разнообразия, а также относительной численности таксонов. Особенно сильно эти искажения проявляются в высокодиверсифицированных сообществах (каковыми являются почвенные микробиоты): вложенный ПЦР генерирует огромное количество ложных редких операционных таксономических единиц (Operational Taxonomic Unit, OTU), которые вносят пренебрежимый вклад в реальную биомассу, но создают иллюзию высокого разнообразия [20].

С другой стороны, недавние исследования показывают, что полный отказ от вложенного ПЦР не всегда возможен. Работа Leclerc et al. (2025) [21], посвященная оптимизации метабаркодинга гена *rpoB* для образцов с низкой концентрацией бактериальной ДНК, доказала, что при строгой оптимизации количества циклов (например, 25 циклов в первом раунде и 15 во втором) вложенный ПЦР позволяет успешно амплифицировать мишень без существенных искажений состава сообщества, которые наблюдаются при стандартном ПЦР с 40 циклами. Тем не менее авторы подчеркивают, что эффективность метода в высокой степени зависит от качества и специфичности используемых праймеров [21].

Таким образом, в анализе популяций ризобий формируется серьезная коллизия. С одной стороны, высокая вариабельность целевых генов (например, симбиотических генов, находящихся на мобильных элементах [24]) и низкая концентрация ДНК в почве вынуждают исследователей использовать вырожденные праймеры и прибегать к вложенному ПЦР. С другой стороны, использование недостаточно специфичных праймеров и дополнительные циклы амплификации делают полученные данные нерепрезентативными из-за ПЦР-смещений [8; 20].

Разрешение этого противоречия может лежать не в плоскости молекулярной биологии, а в области вычислительной биологии и биоинформатики. Ключевым фактором успеха является строгий *in silico* дизайн праймеров, учитывающий термодинамику всего пула вырожденных олигонуклеотидов. Это обосновывает актуальность разработки специализированного программного обеспечения (рассматриваемого в данной работе), способного решать задачи дизайна вырожденных праймеров на уровне строгих математических моделей термодинамики нуклеиновых кислот.

Как будет продемонстрировано в главе 4, применение таких термодинамически сбалансированных праймеров в комбинации с современными алгоритмами вероятностного денойзинга позволяет успешно применять протоколы вложенной ПЦР для анализа сложных почвенных образцов, нивелируя описанные выше риски генерации ложных редких таксонов.

1.3 Математические модели термодинамики нуклеиновых кислот. Модели SantaLucia и Zuker. Проблема расчета параметров для вырожденных (IUPAC) последовательностей

Успешность полимеразной цепной реакции (ПЦР) и специфичность связывания праймера с матрицей определяются не только фактом комплементарности последовательностей, но и строгими физико-химическими законами термодинамики нуклеиновых кислот. В контексте анализа высоковариабельных генов почвенной микробиоты, где требуется использование вырожденных праймеров, точное математическое моделирование этих процессов становится решающим фактором, определяющим отсутствие ПЦР-смещения [8].

Фундаментальной задачей при дизайне праймеров является предсказание их вторичных структур (т.н. проблема фолдинга) и температуры плавления (T_m). Классическим алгоритмом решения задачи предсказания вторичной структуры

одноцепочечных нуклеиновых кислот является алгоритм, предложенный М. Цукером (M. Zuker) и основанный на методе динамического программирования [43]. Данный алгоритм позволяет найти структуру с минимальной свободной энергией Гиббса (ΔG) за полиномиальное время $O(N^3)$, где N — длина последовательности. Алгоритм Цукера учитывает образование различных структурных мотивов: стэков (спиральных участков), шпилек (hairpins), внутренних петель (internal loops) и раздувов (bulges). Поскольку длина ПЦР-праймеров обычно не превышает 20–30 нуклеотидов, вычислительная сложность $O(N^3)$ требует пренебрежимо малых затрат процессорного времени, что делает алгоритм идеальным инструментом для высокопроизводительного скрининга.

Термодинамической базой для алгоритмов фолдинга и расчета T_m служит модель ближайших соседей (Nearest-Neighbor, NN), параметризованная в фундаментальных работах Дж. СантаЛюсии (J. SantaLucia Jr.) [34; 35]. В отличие от устаревших эмпирических правил, учитывающих лишь процентное содержание ГЦ-пар, NN-модель постулирует, что стабильность дуплекса определяется не отдельными водородными связями, а стэкинг-взаимодействиями между соседними парами оснований [35].

Свободная энергия образования дуплекса рассчитывается как сумма вкладов всех димерных стэков и параметров инициации:

$$\Delta G_{total}^{\circ} = \Delta G_{init}^{\circ} + \Delta G_{sym}^{\circ} + \sum_{k=1}^{N-1} \Delta G_{stack}^{\circ}(k, k+1), \quad (1.1)$$

где ΔG_{sym}° — энтропийный штраф за симметрию (применяется только для самокомплементарных дуплексов), ΔG_{init}° — энергия инициации дуплекса, которая включает в себя штраф за нестабильность концевых А-Т-пар (поскольку они удерживаются лишь двумя водородными связями), а ΔG_{stack}° — табличные значения свободной энергии для 10 возможных пар соседних оснований Уотсона-Крика [34].

Поскольку табличные параметры NN-модели исторически приводятся к стандартной физиологической температуре 37°C (310.15°K), расчет свободной энергии при произвольной температуре T (например, при температуре отжига ПЦР) осуществляется через энтальпию (ΔH°) и энтропию (ΔS°) тех же NN-параметров по уравнению Гиббса-Гельмгольца: $\Delta G_T^{\circ} = \Delta H^{\circ} - T\Delta S^{\circ}$.

Зная энтальпию и энтропию, температуру плавления (T_m) для бимолекулярного дуплекса можно рассчитать, решив уравнение двухстадийного равновесия:

$$T_m = \frac{\Delta H^\circ \times 1000}{\Delta S^\circ + R \ln \left(\frac{C_T}{x} \right)} - 273.15, \quad (1.2)$$

где ΔH° — изменение энтальпии (ккал/моль), ΔS° — изменение энтропии (кал/(моль·К)), R — универсальная газовая постоянная (1.987 кал/(моль·К)), C_T — общая концентрация олигонуклеотидов, а x — статистический фактор (4 для несамокомплементарных и 1 для самокомплементарных дуплексов) [34]. Множитель 1000 в числителе переводит килокалории в калории, согласуя единицы измерения энтальпии и энтропии. Модель СантаЛюсии также включает строгие эмпирические поправки на ионную силу раствора, без чего моделирование реальных ПЦР-буферов невозможно [35].

Однако наиболее распространённые модели, лежащие в основе большинства биоинформатических пакетов, содержат фундаментальное ограничение: в немодифицированном виде они не годятся для работы с *вырожденными праймерами*, то есть последовательностями, содержащими символы кода IUPAC (например, R = A или G, N = любое основание), которые физически представляют собой эквимольные смеси d невырожденных вариантов (здесь d характеризует степень вырожденности), и поэтому требуют модификации.

Традиционные подходы к дизайну вырожденных праймеров, такие как программа HYDEN [15], используют комбинаторные модели, подсчитывая количество несовпадений (mismatches) между праймером и матрицей. Такой подход игнорирует биофизику процесса: из-за эффекта ближайших соседей два разных варианта вырожденного праймера, имеющие одинаковое число несовпадений с мишенью, могут обладать различными значениями T_m и ΔG .

Оценка термодинамики некой «усредненной» или «консенсусной» последовательности ведёт к ошибкам в расчётах. В реальности в ПЦР-ячейке возникает конкуренция между вариантами праймера. Варианты с более высокой T_m и более отрицательным ΔG связывания будут эффективнее отжигаться на ДНК-матрице. Это приводит к значительному ПЦР-смещению, когда истинное разнообразие симбиотических или хромосомных генов в почвенном образце искажается, а редкие аллели полностью теряются [8; 20].

Таким образом, возникает сложная вычислительная проблема: для корректного дизайна вырожденных праймеров необходимо рассчитывать *ансамблевую*

термодинамику. Требуется рассматривать каждый вырожденный олигонуклеотид как пул его недвусмысленных вариантов, для каждого из них с помощью алгоритма динамического программирования (Цукера) и NN-параметров (СантаЛюсии) рассчитывать ΔG фолдинга и ΔG гибридизации, а затем агрегировать эти значения в статистические распределения.

Поскольку задача проектирования вырожденных праймеров (Degenerate Primer Design, DPD) сама по себе является NP-трудной [15], добавление строгого термодинамического моделирования для каждого варианта в пуле приводит к экспоненциальному росту вычислительной сложности. Это обосновывает необходимость разработки новых, высокопроизводительных алгоритмов и использования современных языков программирования (таких как Julia [13]), способных обеспечить необходимую вычислительную эффективность. Именно эта проблема — отсутствие в существующем ПО поддержки ансамблевой термодинамики для олигонуклеотидов с вырожденными позициями — формирует научный задел для разработки вычислительного ядра SeqFold.jl и пакета DePPA.jl, описываемых в данной работе.

1.4 Анализ существующего программного обеспечения. Обоснование неприменимости классических инструментов для ансамблевой термодинамики

Развитие методов ПЦР и высокопроизводительного секвенирования стимулировало создание широкого спектра биоинформатических инструментов для дизайна праймеров. Подробный обзор существующего бесплатного программного обеспечения представлен в работе Guo et al. (2021) [10]. Однако, как будет показано ниже, ни один из существующих инструментов не решает в полной мере задачу расчета ансамблевой термодинамики для вырожденных праймеров.

Primer3 и его производные. Primer3 [14; 27; 32] на данный момент является «золотым стандартом» и вычислительным движком для множества специализированных инструментов, таких как AutoPrime [42], QuantPrime [44] и Primer-BLAST [26]. Однако Primer3 предназначен исключительно для работы с *одиночными, невырожденными последовательностями*. Он не поддерживает нативную работу с множественными выравниваниями (MSA), что делает его неприменимым для задач дизайна праймеров по высоковариабельным семействам генов почвенной микробиоты.

Инструменты для дизайна вырожденных праймеров. Для работы с множественными выравниваниями был разработан ряд специализированных инструментов. Пионерская программа HYDEN [15] формализовала задачу проектирования вырожденных праймеров как NP-трудную комбинаторную проблему, однако использовала комбинаторную модель несовпадений, игнорируя биофизику NN-модели. Инструменты Amplicon [12] и Primaclade [25] используют базовые эвристики для оценки T_m и опираются на устаревшие программные стеки. Более современный пакет OpenPrimeR [19; 23], написанный на языке R, позволяет оценивать покрытие праймеров, но применяет упрощенные модели для расчета T_m и ΔG , не поддерживая расчет термодинамических распределений для всего пула вариантов. Инструмент DeGenPrime [7] использует каскад фильтров, но также не поддерживает расчет ансамблевых характеристик и обладает ограничениями в гибкости настройки длины целевого ампликона.

Коммерческие решения. Коммерческие пакеты, такие как Geneious Prime [3] и CLC Genomics Workbench [28], предлагают базовую поддержку IUPAC-кодов и могут проектировать праймеры на основе консенсусных последовательностей из MSA. Однако их алгоритмы опираются на упрощенные термодинамические эвристики (часто — учитывающие только GC-состав) и не рассчитывают статистические распределения T_m и ΔG для гетерогенных систем. Кроме того, закрытая архитектура и проприетарные лицензии делают их непригодными для встраивания в открытые научные пайплайны.

Резюме по анализу ПО. Проведенный обзор показывает, что существующее программное обеспечение обладает фундаментальным ограничением: ни один из открытых или коммерческих инструментов не поддерживает нативный расчет *ансамблевой термодинамики* для вырожденных праймеров на основе строгой NN-модели СантаЛюсии и алгоритма динамического программирования Цукера. Все существующие решения либо работают с одиночными последовательностями (Primer3), либо используют комбинаторные модели несовпадений (HYDEN), либо применяют упрощенные термодинамические эвристики (OpenPrimeR).

Отсутствие подобных инструментов в открытой экосистеме, способных обеспечить строгий термодинамический контроль пулов олигонуклеотидов с высокой вычислительной эффективностью, обосновывает необходимость разработки специализированного программного обеспечения, математические модели и архитектура которого будут рассмотрены в следующих главах.

1.5 Выводы по главе 1

Проведенный в первой главе обзор литературы показал, что изучение свободноживущих популяций ризобий в почве методами классической микробиологии ограничено эффектом «некультивируемости» и селективным смещением при высеве на питательные среды. Альтернативой выступает высокопроизводительное секвенирование ампликонов, однако анализ почвенной экологической ДНК сопряжен с экстремально низкой концентрацией целевых генов и их высокой генетической вариабельностью, обусловленной локализацией симбиотических генов на мобильных генетических элементах. Это диктует необходимость использования сильно вырожденных праймеров и протоколов вложенной ПЦР, что, в свою очередь, усиливает проблему ПЦР-смещения и искажает оценку реального микробного разнообразия.

Установлено, что ПЦР-смещение при работе с вырожденными праймерами имеет фундаментальную биофизическую природу. Традиционные подходы, оперирующие усредненными консенсусными последовательностями или комбинаторными моделями несовпадений, игнорируют статистическую гетерогенность реальных химических пулов олигонуклеотидов. Для адекватного моделирования процесса отжига необходимо рассчитывать ансамблевую термодинамику — статистические распределения температуры плавления (T_m) и свободной энергии Гиббса (ΔG) для всех вариантов вырожденного праймера, опираясь на строгую модель ближайших соседей (SantaLucia) и алгоритм динамического программирования предсказания вторичной структуры (Zuker).

Критический анализ существующего программного обеспечения выявил их непригодность к нативному расчету ансамблевой термодинамики для IUPAC-последовательностей. Отсутствие подобных инструментов в открытой экосистеме обосновывает необходимость разработки специализированного высокопроизводительного программного обеспечения на языке Julia, способного обеспечить строгий термодинамический контроль.

Для решения выявленных проблем во второй главе будут формализованы математические модели и разработаны алгоритмы конструирования вырожденных ПЦР-праймеров с учетом ансамблевых термодинамических факторов, которые лягут в основу архитектуры вычислительного ядра SeqFold.jl и пакета DePPA.jl.

ГЛАВА 2 МАТЕМАТИЧЕСКИЕ МОДЕЛИ И АЛГОРИТМЫ КОНСТРУИРОВАНИЯ ВЫРОЖДЕННЫХ ПЦР-ПРАЙМЕРОВ

Целью данной главы является разработка математических моделей и алгоритмов конструирования вырожденных праймеров, опирающихся на расчет ансамблевой термодинамики.

В параграфе 2.1 приводится формализация задачи дизайна праймеров на основе множественного выравнивания и формулируется система геометрических и термодинамических ограничений. Параграф 2.2 посвящен алгоритмам расчета статистических распределений свободной энергии и температуры плавления для пулов олигонуклеотидов. В завершение главы формулируются основные выводы, обобщающие разработанный математический аппарат.

2.1 Формализация задачи дизайна праймеров на основе множественного выравнивания

Успешная амплификация высоковариабельных генов почвенной микробиоты требует учета всего спектра генетического разнообразия целевых локусов. Множественное выравнивание последовательностей (Multiple Sequence Alignment, MSA) служит естественным входным представлением, фиксирующим консервативные и вариабельные участки исследуемых геномов.

Формально, пусть задано выравнивание M , состоящее из N последовательностей длиной L . В отличие от классических подходов, работающих с алфавитом невырожденных символов, рассматриваемая постановка предполагает использование расширенного алфавита IUPAC, включающего коды для неоднозначных позиций (таблица 2.1).

Каждый столбец j выравнивания M формализуется не как жесткий набор символов, а как вектор вероятностей появления четырёх базовых нуклеотидов $\mathbf{p}_j$. Для позиции j вектор частот вычисляется согласно выражению:

$$p_b^{(j)} = \frac{1}{N} \sum_{i=1}^N w(s_i^{(j)}, b), \quad (2.1)$$

где $w(s, b)$ — вес основания b в символе s алфавита IUPAC. Для однозначных нуклеотидов $w = 1$ при совпадении и 0 иначе; для вырожденных кодов вес распределяется равномерно между допустимыми основаниями.

Таблица 2.1

Расшифровка кодов нуклеотидов IUPAC

Код	Основания	Описание	Код	Основания	Описание
A	A	Аденин	K	G, T	Кето
C	C	Цитозин	M	A, C	Амино
G	G	Гуанин	S	C, G	Сильные связи
T	T	Тимин	W	A, T	Слабые связи
R	A, G	Пурины	B	C, G, T	Все кроме A
Y	C, T	Пиримидины	D	A, G, T	Все кроме C
V	A, C, G	Все кроме T	H	A, C, T	Все кроме G
N	A, C, G, T	Любой	-	-	Пропуск (gap)

Для формирования консенсусной последовательности праймера вводится параметр пороговой частоты (slack) $\sigma \in [0, 1]$. Множество оснований B_j , включаемых в вырожденный консенсус для позиции j , определяется условием:

$$B_j = \{b \in \{A, C, G, T\} \mid p_b^{(j)} > \sigma\}. \quad (2.2)$$

Степень вырожденности позиции определяется как $d_j = |B_j|$. Общий пул уникальных (невырожденных) олигонуклеотидов, кодируемых праймером длины k , имеет размер V , вычисляемый по формуле:

$$V = \prod_{j=1}^k d_j. \quad (2.3)$$

Праймер структурно разделяется на 5'-область (голову, head) и 3'-область (хвост, tail). Задача дизайна праймера формулируется как поиск окна $W = [i, i + k - 1]$ в выравнивании M , удовлетворяющего системе геометрических, композиционных и термодинамических ограничений.

Геометрические и композиционные ограничения. Глубина покрытия в позиции j , учитывающая долю последовательностей, содержащих валидный нуклеотид, не должна опускаться ниже порога $d_{\min}$:

$$d_j^{\text{cov}} = \min \left(1, \sum_{b \in \{A, C, G, T\}} p_b^{(j)} \right) \geq d_{\min}. \quad (2.4)$$

Консенсусная последовательность не должна содержать символов пропусков («—»). Для обеспечения специфичности отжига число вырожденных позиций строго лимитируется отдельно для 5'-головки и 3'-хвоста:

$$|\{j \in H \mid d_j > 1\}| \leq D_{\text{head}}, \quad |\{j \in T \mid d_j > 1\}| \leq D_{\text{tail}}. \quad (2.5)$$

Как правило, $D_{\text{tail}} = 0$, так как комплементарность 3'-конца обязательна для инициации элонгации ДНК-полимеразой. Общее количество уникальных последовательностей ограничено технологическими рамками синтеза ($V \leq V_{\text{max}}$). GC-состав рассчитывается как математическое ожидание и должен удовлетворять ограничению:

$$\text{GC}_{\min} \leq \frac{1}{k} \sum_{j \in W} \left(p_G^{(j)} + p_C^{(j)} \right) \leq \text{GC}_{\max}. \quad (2.6)$$

Термодинамические ограничения. Данные ограничения играют ключевую роль в минимизации ПЦР-смещений. Температура плавления T_m оценивается как статистическое распределение для всего пула из V уникальных олигонуклеотидов. Ограничение накладывается на доверительный интервал T_m , который должен пересекаться с допустимым диапазоном температур:

$$[T_m^{\text{lower}}, T_m^{\text{upper}}] \cap [T_{m,\min}, T_{m,\max}] \neq \emptyset. \quad (2.7)$$

Свободная энергия Гиббса вторичных структур ΔG_{fold} , оцениваемая при референсной температуре T_{ref} , не должна быть ниже порогового значения $\Delta G_{\min}$ (где $\Delta G_{\min} < 0$), что предотвращает образование термодинамически слишком стабильных вторичных структур:

$$\Delta G_{\text{fold}}(W, T_{\text{ref}}) \geq \Delta G_{\min}. \quad (2.8)$$

Сопряжение праймеров (pairing). Завершающим этапом является решение задачи сопряжения прямого (forward) и обратного (reverse) праймеров. Пусть $W_F = [i_F, j_F]$ и $W_R = [i_R, j_R]$ — окна выравнивания для прямого и обратного праймеров соответственно. Пара признаётся валидной, если выполняются условия отсутствия перекрытия (2.9), попадания длины ампликона в заданный диапазон (2.10) и синхронного отжига (2.11):

$$i_R > j_F, \quad (2.9)$$

$$L_{\min} \leq j_R - i_F + 1 \leq L_{\max}, \quad (2.10)$$

$$\left| \bar{T}_{m,F} - \bar{T}_{m,R} \right| \leq \Delta T_{m,\max}, \quad (2.11)$$

где $\bar{T}_{m,F}$ и $\bar{T}_{m,R}$ представляют собой средние значения температур плавления, вычисленные как среднее арифметическое по всем уникальным вариантам прямого и обратного праймеров соответственно.

Таким образом, задача дизайна сводится к многокритериальной фильтрации пространства всех возможных окон выравнивания с последующим поиском оптимальных непересекающихся пар, удовлетворяющих сформулированной системе ограничений (2.1)–(2.11).

2.2 Алгоритм расчета ансамблевой термодинамики для пулов олигонуклеотидов

Вырожденный праймер в реакционной смеси представляет собой эквимольный пул из V различных невырожденных олигонуклеотидов. Каждый из этих вариантов обладает уникальными термодинамическими свойствами: образует вторичные структуры и дуплексы с матрицей с собственной энергией связывания. Усреднение нуклеотидной последовательности до этапа расчета T_m или ΔG приводит к физически некорректным результатам, так как термодинамические параметры не являются линейными функциями от состава. Вместо этого расчет выполняется независимо для каждого из V вариантов с последующей агрегацией в ансамблевые статистики.

Для каждого невырожденного варианта S_v ($v = 1, \dots, V$) рассчитывается минимальная свободная энергия его вторичной структуры ΔG_v при заданной температуре T с использованием алгоритма динамического программирования Цукера [43]. Поскольку исходные варианты праймера присутствуют в растворе в равных молярных концентрациях, их вклад в общую термодинамику системы определяется вероятностью нахождения в свернутом состоянии. Согласно статистической физике, эта вероятность пропорциональна фактору Больцмана $\exp(-\Delta G_v/RT)$. Ансамблевая свободная энергия фолдинга пула ΔG_{ens} вычисляется через статистическую сумму (больцмановское усреднение), что корректно отражает вклад высокостабильных вторичных структур, которые могут выпадать из реакции отжига:

$$\Delta G_{\text{ens}} = -RT \ln \left(\frac{1}{V} \sum_{v=1}^V \exp \left(-\frac{\Delta G_v}{RT} \right) \right), \quad (2.12)$$

где R — универсальная газовая постоянная. Для численного вычисления выражения (2.12) при больших значениях аргумента экспоненты применяется алгоритмически устойчивая функция логарифмирования суммы экспонент (`logsumexp`), предотвращающая переполнение разрядной сетки.

Для оценки температуры плавления (T_m) дуплекса праймер-матрица для каждого варианта S_v величина $T_{m,v}$ рассчитывается по модели ближайших соседей (Nearest-Neighbor, NN) [35] с учетом энтальпии и энтропии стэкинг-взаимодействий, а также строгих эмпирических поправок на ионную силу реакционного буфера.

Ансамблевая температура плавления описывается не единственным значением, а статистическим распределением, для которого вычисляются:

- среднее значение $\bar{T}_m = \frac{1}{V} \sum_{v=1}^V T_{m,v}$;
- доверительный интервал $[T_m^{\text{lower}}, T_m^{\text{upper}}]$, определяемый как эмпирические квантили уровня $\alpha/2$ и $1 - \alpha/2$ (например, 10-й и 90-й процентиля для 80%-ного интервала);
- абсолютные границы $[T_m^{\text{min}}, T_m^{\text{max}}]$, которые детерминированно оцениваются путем расчета T_m для вариантов с минимальным и максимальным GC-составом в пуле.

Требование попадания доверительного интервала $[T_m^{\text{lower}}, T_m^{\text{upper}}]$ в заданный диапазон температур отжига гарантирует, что подавляющее большинство вариантов праймера будет эффективно связываться с матрицей без образования неспецифических продуктов.

Различие в методах агрегации термодинамических параметров обусловлено их физической природой. Свободная энергия Гиббса (ΔG) является термодинамическим потенциалом, экспоненциально определяющим вероятность микросостояний системы (распределение Больцмана). Поскольку полная статистическая сумма ансамбля складывается из вкладов отдельных вариантов, расчет эффективной энергии требует применения статистической суммы. Температура плавления (T_m), напротив, представляет собой макроскопическую температуру фазового перехода. Поскольку молекулы в растворе диссоциируют независимо, а экспериментально наблюдаемый сигнал является линейной суперпозицией вкладов всех молекул, макроскопическая кривая плавления эквимольной смеси и её характеристические температуры описываются арифметическим усреднением индивидуальных значений $T_{m,v}$.

Важной биофизической характеристикой, критичной для эффективности ПЦР, является доля молекул праймера, находящихся в одноцепочечной (расплавленной) форме и доступных для гибридизации с мишенью. Для каждого варианта S_v константа равновесия фолдинга $K_{f,v} = \exp(-\Delta G_v/RT)$, а доля расплавленных

молекул составляет:

$$f_{\text{unfolded},v} = \frac{1}{1 + K_{f,v}} = \frac{1}{1 + \exp(-\Delta G_v/RT)}. \quad (2.13)$$

Ансамблевая доля доступных для отжига молекул вычисляется как среднее арифметическое по всем вариантам пула:

$$\bar{f}_{\text{unfolded}} = \frac{1}{V} \sum_{v=1}^V f_{\text{unfolded},v}. \quad (2.14)$$

Данный параметр позволяет первично отсеивать праймеры, значительная часть пула которых при температуре отжига заблокирована стабильными вторичными структурами.

Однако одной лишь средней величины $\bar{f}_{\text{unfolded}}$ недостаточно для гарантии репрезентативной амплификации. Не менее критичным параметром является дисперсия долей расплавленных молекул внутри пула, которая формализуется следующим выражением:

$$\sigma_f^2 = \frac{1}{V} \sum_{v=1}^V \left(f_{\text{unfolded},v} - \bar{f}_{\text{unfolded}} \right)^2. \quad (2.15)$$

Высокое значение дисперсии σ_f^2 указывает на сильную термодинамическую гетерогенность пула: различные варианты олигонуклеотидов в реакционной смеси расплетаются и отжигаются на ДНК-матрице в существенно разных пропорциях. В результате варианты с высокой долей $f_{\text{unfolded},v}$ будут амплифицироваться эффективно, в то время как молекулы с низкой долей, заблокированные вторичными структурами, выпадут из реакции. Это неравенство эффективностей напрямую усиливает ПЦР-смещение, искажая итоговое соотношение ампликонов и подавляя редкие таксоны.

Для наглядной демонстрации этого эффекта был проведен вычислительный эксперимент. Базовый невырожденный олигонуклеотид длиной 20 п.н. был использован как шаблон для генерации пулов вырожденных вариантов. Путем случайного внесения IUPAC-неоднозначностей формировались пулы размером $V = 1, 20, 100$ и 400 уникальных последовательностей. Для каждого пула рассчитывалась зависимость доли расплавленных (несвернутых) молекул от температуры в диапазоне от 0 до 100 °C, а также вычислялась средняя доля доступных для отжига молекул и доверительный интервал в целевом диапазоне температур отжига (55–60 °C).




Рис.2.1. Кривые плавления (доля несвернутых молекул) для пулов праймеров с благоприятным термодинамическим профилем. Кривые выходят на насыщение уже при $\sim 40^\circ\text{C}$. Увеличение размера пула практически не меняет среднюю долю расплавленных молекул и ширину доверительного интервала в диапазоне $55\text{--}60^\circ\text{C}$. Такой праймер обеспечивает стабильную и репрезентативную амплификацию.

На рис. 2.1, 2.2, 2.3 представлены три контрастных примера, иллюстрирующих различные сценарии поведения пулов праймеров.

Первый пример (рис. 2.1) демонстрирует «идеальный» профиль: кривые плавления для всех вариантов пула выходят на насыщение уже при $\sim 40^\circ\text{C}$. В целевом диапазоне температур ($55\text{--}60^\circ\text{C}$) практически все молекулы находятся в расплавленной форме, а увеличение степени вырожденности (от $V = 1$ до $V = 400$) не приводит к существенному росту разброса (доверительный интервал остается узким). Это гарантирует, что все варианты праймера будут эффективно участвовать в амплификации без ПЦР-смещения.

Второй пример (рис. 2.2) показывает пул с чрезмерно стабильными вторичными структурами. Кривые выходят на насыщение лишь при высоких температурах,




Рис.2.2. Кривые плавления для пулов праймеров со слишком стабильными вторичными структурами. Несмотря на малый разброс, в рабочем диапазоне температур (55–60 °C) доля несвернутых молекул составляет лишь 2–3%. Большая часть пула заблокирована шпильками, что приведет к резкому падению выхода ампликона.

при этом разброс между вариантами минимален. Однако в диапазоне 55–60 °C доля расплавленных молекул составляет всего 2–3%. Расчет для единичного консенсуса мог бы не выявить этой проблемы, но ансамблевый анализ помогает отсеять такой праймер как неэффективный.

Третий пример (рис. 2.3) является наиболее показательным и демонстрирует опасность использования усредненных консенсусов. Для единичной невырожденной последовательности ($V = 1$) доля расплавленных молекул в рабочем диапазоне высока (93%), что свидетельствует о пригодности такого невырожденного праймера. Однако с увеличением размера пула до $V = 20$ (что типично для слабовырожденных праймеров, конструируемых для среднеконсервативных участков MSA) средняя доля доступных молекул в исследуемом температурном окне падает до 77%, а ширина доверительного интервала возрастает до 24 процентных пунктов.




Рис.2.3. Пример с высоким разбросом стабильности вторичных структур. Для единственной последовательности ($V = 1$) доля несвернутых молекул при 55–60 °C составляет 93% с малым разбросом. Однако при увеличении пула до $V = 20$ (типичный размер для слабовырожденных праймеров) средняя доля падает до 77%, а ширина доверительного интервала достигает 24 процентных пунктов, указывая на сильное ПЦР-смещение.

Такой огромный разброс означает, что одни варианты праймера будут эффективно отжигаться, а другие — образовывать стабильные вторичные структуры и выпадать из реакции, что неизбежно приведет к сильному ПЦР-смещению. При дальнейшем росте пула ($V = 100$ и $V = 400$) доверительный интервал сужается (до 7 и 4 п.п. соответственно) за счет статистического усреднения, но именно на промежуточных размерах ($V \approx 20$), характерных для этапа дизайна, нежелательных ПЦР-смещений максимален.

Таким образом, представленные примеры наглядно подтверждают, что оценка ансамблевой термодинамики и расчет распределения доли расплавленных молекул являются критически необходимыми для отбора праймеров, обеспечивающих репрезентативную амплификацию всего генетического разнообразия мишени.

Критерий фильтрации должен включать не только нижнюю границу для среднего $\bar{f}_{\text{unfolded}} \geq f_{\text{min}}$, но и верхнее ограничение на дисперсию $\sigma_f^2 \leq \sigma_{\text{max}}^2$.

Вычислительная сложность описанного алгоритма линейно зависит от размера пула V и кубически от длины праймера k (обусловлено сложностью алгоритма Цукера $O(k^3)$). Для слабовырожденных праймеров ($V \leq 2^{10}$) вычислительно необременителен полный перебор всех уникальных вариантов. Однако при больших значениях V полный перебор может оказаться нецелесообразным. В таких случаях допускается оценка методом Монте-Карло: из пула равномерно сэмпляется N случайных невырожденных вариантов, по которым вычисляются выборочные статистики $\bar{T}_m$, доверительные интервалы, $\bar{f}_{\text{unfolded}}$ и σ_f^2 . Данный подход сохраняет высокую производительность вычислений даже для высоковырожденных олигов.

2.3 Выводы по главе 2

В главе формализована задача конструирования вырожденных ПЦР-праймеров на основе множественного выравнивания последовательностей. Сформулирована система геометрических, композиционных и термодинамических ограничений, накладываемых на кандидатов в праймеры и их пары. Обоснована некорректность расчета термодинамических параметров для усредненных консенсусных последовательностей и разработан алгоритм оценки ансамблевой термодинамики, позволяющий рассчитывать статистические распределения температуры плавления (T_m) и свободной энергии Гиббса (ΔG) вторичных структур для всего пула уникальных вариантов праймера.

Представленные математические модели формируют теоретический фундамент для дизайна праймеров, минимизирующих ПЦР-смещения. Однако вычислительная сложность независимого расчета термодинамики для каждого варианта в пуле (особенно при высокой степени вырожденности) обуславливает высокие требования к производительности вычислительного ядра. Архитектура и высокопроизводительная программная реализация описанных алгоритмов на языке Julia будут подробно рассмотрены в следующей главе.

ГЛАВА 3 РАЗРАБОТКА И ОПТИМИЗАЦИЯ ПРОГРАММНОГО ОБЕСПЕЧЕНИЯ ДЛЯ ТЕРМОДИНАМИЧЕСКОГО АНАЛИЗА

Целью данной главы является описание архитектуры, программной реализации и оптимизации производительности разработанного вычислительного инструментария. Математические модели и алгоритмы, формализованные во второй главе, налагают высокие требования к быстродействию, поскольку расчет ансамблевой термодинамики требует многократного независимого моделирования для каждого варианта в пуле вырожденных олигонуклеотидов.

В разделе 3.1 рассматривается процесс портирования, верификации и оптимизации вычислительного ядра `SeqFold.jl` на языке Julia. Раздел 3.2 посвящен проектированию модульной архитектуры и алгоритмической реализации пакета `DePPA.jl`, решающего задачу комбинаторного поиска и фильтрации праймерных пар.

3.1 Архитектура, верификация и инфраструктура вычислительного ядра `SeqFold.jl`



Рис.3.1. Общий вид заглавной страницы в GitHub-репозитории проекта `SeqFold.jl`

Вычислительное ядро `SeqFold.jl` [2] представляет собой высокопроизводительную реализацию алгоритмов предсказания вторичной структуры нуклеиновых кислот (метод динамического программирования Цукера) и расчета температуры плавления (T_m) на основе модели ближайших соседей [34]. Базовые математические модели, лежащие в основе этих расчетов, были подробно рассмотрены в главе 2. Целью данного раздела является описание архитектурных решений,

процесса портирования, оптимизации производительности и инфраструктурного обеспечения пакета, разработанного в рамках данной ВКР.

Портирование, верификация и устранение критических ошибок. Исходной точкой для разработки послужила библиотека `seqfold`, написанная на языке Python [36]. Основной задачей на начальном этапе являлся не только перенос логики на язык Julia, но и строгая верификация: обеспечение побитовой идентичности результатов для всех возможных входных данных. В ходе написания юнит-тестов и сравнения с эталонной Python-реализацией был выявлен ряд ошибок в исходном коде последней.

Наиболее существенной ошибкой являлась некорректная реализация расчета солевой поправки к энтропии (ΔS°) на основе модели Owczarzy et al. (2008) [35]. В исходном Python-пакете логика ветвления при расчете эффективной концентрации магния (Mg^{2+}) и моновалентных катионов (*Mon*) содержала жесткие допущения, из-за чего расчет T_m давал физически некорректные результаты (вплоть до отрицательных абсолютных температур) для любых буферных условий, отличных от стандартного пресета `pcr`. В `SeqFold.jl` функция `_calc_tm` была полностью переписана: реализован корректный расчет диссоциации комплекса $Mg:dNTPs$ и безопасное вычисление логарифмов ионных сил, что гарантировало термодинамическую консистентность при любых пользовательских концентрациях ионов.

Оптимизация производительности и типовая стабильность. Язык программирования Julia обеспечивает производительность, сопоставимую с C/C++, однако для достижения этого её компилятор требует соблюдения стабильности типов. Исходный Python-код не накладывал подобных ограничений, поэтому при портировании потребовалось изменение архитектурных подходов к хранению данных и написанию вычислительных функций.

В частности, в исходной реализации словари термодинамических параметров (например, `tri_tetra_loops`) допускали отсутствие ключей, что в Julia приводило к использованию типов `Union{Nothing, Float64}`. Это вызывало деградацию производительности из-за необходимости динамической диспетчеризации типов на каждом шаге рекурсии. В `SeqFold.jl` структуры данных были переупакованы: отсутствующие значения были заменены на `Inf` или `0.0` в зависимости от физического смысла, что позволило компилятору Julia генерировать оптимальный машинный код без накладных расходов на проверку типов.

Ярким примером написания высокопроизводительного и численно устойчивого кода в Julia является реализация функции агрегации ансамблевой свободной энергии (см. формулу (2.12)). Для предотвращения переполнения разрядной сетки при вычислении суммы экспонент используется алгоритмически устойчивый метод `logsumexp`. Листинг 3.1 демонстрирует ключевые идиомы языка, обеспечивающие максимальную производительность.

```
function logsumexp(x::Vector{T}) where T <: Number
    m = maximum(x)
    isinf(m) && return m
5   s = sum(exp(val - m) for val in x, init=zero(T))
    return m + log(s)
end
```

Листинг 3.1

Реализация численно устойчивой функции `logsumexp`

В приведенном листинге конструкция `where T <: Number` осуществляет параметризацию функции по типу элемента вектора. Это означает, что при первом вызове функции для вектора с числовым типом данных компилятор Julia сгенерирует и скомпилирует специализированную версию функции именно для этого типа, что исключает накладные расходы на динамическую диспетчеризацию внутри цикла. Использование функции `zero(T)` вместо литерала `0.0` гарантирует стабильность типа переменной-сумматора `s`: его тип будет строго соответствовать типу элементов вектора, предотвращая неявные преобразования типов, которые могут привести к деградации скорости вычислений.

Подобные решения — параметризация типов, множественная диспетчеризация (`multiple dispatch`), строгая типизация полей составных типов и макросы оптимизации (`@inbounds`, который разрешает компилятору не проверять границы индексов при доступе к элементу массива, и `@simd` для векторизации циклов) — являются стандартом при разработке на Julia. Они позволяют писать лаконичный, обобщенный код, сохраняя при этом производительность, сопоставимую с низкоуровневыми языками программирования, что полезно для задач, требующих многократного расчета термодинамики для тысяч вариантов вырожденных праймеров в рамках ансамблевого подхода.

Сравнение производительности. Для оценки вычислительной эффективности разработанного ядра `SeqFold.jl` было проведено сравнение с оригинальной Python-библиотекой `seqfold` и стандартным инструментом `Biopython`. На

рис. 3.2 представлены результаты измерения времени выполнения функций расчета температуры плавления (t_m) и предсказания вторичной структуры ($fold$) для последовательностей различной длины.




Рис.3.2. Сравнение производительности вычислительного ядра SeqFold.jl с оригинальной Python-библиотекой seqfold и Biopython при расчете температуры плавления (t_m) и вторичной структуры ($fold$) для последовательностей типичной рабочей длины.

Как видно из графиков, SeqFold.jl демонстрирует многократное преимущество в скорости ($\times 4.4$ для расчёта T_m и $\times 22.4$ для расчёта вторичных структур) над оригинальным пакетом на Python. Это обусловлено как отсутствием накладных расходов на интерпретацию, так и агрессивной оптимизацией циклов и работы с памятью, что делает разработанное ядро оптимальным вычислительным фундаментом для пакета DePPA.jl.

Инфраструктура пакета, тестирование и экосистема. Разработка SeqFold.jl велась в строгом соответствии с современными стандартами экосистемы Julia. Пакет имеет стандартную структуру директорий (`src/`, `test/`, `docs/`), манифест зависимостей `Project.toml` с жестким контролем совмести-

мости версий и не содержит внешних бинарных зависимостей, что упрощает его установку и интеграцию.

Для обеспечения надежности был написан набор юнит-тестов, покрывающий 85% исходного кода (что подтверждается интеграцией с сервисом Codecov). Непрерывная интеграция (CI) настроена с использованием GitHub Actions: при каждом коммите автоматически запускается матрица тестов на актуальных версиях Julia, а также проводится статический анализ кода с помощью пакета JET.jl и линтер Aqua.jl.

Документация пакета генерируется автоматически из строк документации с использованием Documenter.jl и деплоится на GitHub Pages. Каждая функция и тип обладают подробным описанием API и примерами использования, которые также автоматически проверяются на корректность в CI.

Пакет успешно зарегистрирован в официальном реестре Julia General Registry, что позволяет любому пользователю установить его стандартной командой `Pkg.add("SeqFold")`. Ведется строгое семантическое версионирование. Кроме того, учитывая, что значительная часть биоинформатических пайплайнов написана на языке Python, в документации и README SeqFold.jl представлены инструкции по интеграции в существующие пайплайны на языке Python посредством интерфейса juliacall.

Разработанное ядро SeqFold.jl стало вычислительным фундаментом, на котором был построен специализированный пакет для дизайна вырожденных праймеров DePPA.jl, архитектура которого рассматривается далее.

3.2 Архитектура и программная реализация пакета DePPA.jl




Рис.3.3. Общий вид заглавной страницы в GitHub-репозитории проекта DePPA.jl

Пакет `DePPA.jl` (`Degenerate Primer Pair Assembler`) [1] представляет собой высокоуровневый инструмент для анализа множественных выравниваний и автоматизированного дизайна вырожденных ПЦР-праймеров. В отличие от `SeqFold.jl`, который фокусируется на термодинамике одиночных молекул, `DePPA.jl` решает задачу комбинаторной оптимизации: поиск оптимальных окон в множественном выравнивании (MSA), генерацию вырожденных консенсусов и их строгую термодинамическую фильтрацию. Архитектура пакета спроектирована с упором на модульность, производительность и эргономику интерактивной работы.

Модульная структура и иерархия типов данных. Код пакета разделен на три логических модуля: `Oligos`, `Alignments` и `Primers`. Такое разделение ответственности позволяет использовать компоненты пакета независимо (например, применять `Oligos` и `Alignments` для задач, не связанных с дизайном праймеров).

Иерархия типов данных пакета `DePPA.jl` и общая архитектура проекта, включающая `SeqFold.jl`, представлена на рис. 3.4.

Фундаментом пакета является иерархия абстрактных и конкретных типов для представления нуклеотидных последовательностей, реализованная в модуле `Oligos`:

- `AbstractOligo` — базовый абстрактный тип, наследующий интерфейс `AbstractString`, что позволяет использовать стандартные строковые функции Julia.
- `Oligo` — строгий тип для невырожденных последовательностей (только A, C, G, T).
- `DegenOligo` — тип для вырожденных последовательностей, поддерживающий коды IUPAC. При создании автоматически вычисляет количество вырожденных позиций и общее число уникальных вариантов (`n_unique_oligos`).
- `GappedOligo` — тип для последовательностей с пропусками (гэпами). Для оптимизации потребления памяти он не хранит строку с гэпами напрямую, а содержит ссылку на родительский `DegenOligo` и вектор структур `Pair{Int, Int}`, описывающих позиции и длины гэпов.
- `OligoView` — легковесное представление (view) подпоследовательности, реализующее паттерн zero-copy, что исключает аллокации памяти при слайсинге.

Аналогичная иерархия реализована для множественных выравниваний в модуле `Alignments` (`AbstractMSA`, `MSA`, `MSAView`). Структура `MSA` при инициа-




Рис.3.4. Диаграмма архитектуры пакета DePPA.jl с расширением SeqFold.jl.

ции предварительно вычисляет матрицу частот оснований (`base_count` размером $4 \times L$), что позволяет мгновенно получать профили консервативности и строить консенсусы без повторного сканирования последовательностей.

Механизм слабых зависимостей (Weak Dependencies). Архитектура пакета предусматривает использование механизма расширений (Extensions), введенного в Julia 1.9. Термодинамические расчеты и выравнивание последовательностей вынесены в отдельные модули расширения: `SeqFoldExt` и `MAFFTExt`.

Это означает, что пакеты `SeqFold` и `MAFFT_jll` являются *слабыми зависимостями* (weakdeps). Пользователь может установить `DePPA.jl` для работы с MSA и IUPAC-кодами без загрузки термодинамического движка. Функции дизайна праймеров (`construct_primers`) динамически делегируют вызовы функций `tm`, `dg` и `revcomp` в `SeqFoldExt`, который загружается в память только при явном вызове `using SeqFold`. Такой подход позволяет избежать избыточного времени прекомпиляции и снижает требования к вычислительным ресурсам при выполнении базовых операций с MSA.

Алгоритмическая реализация дизайна праймеров. Процесс конструирования праймеров реализован в функции `construct_primers`, которая принимает на вход объект MSA и набор ограничений, формализованных в главе 2. Алгоритм представляет собой многопоточный скользящий окно-фильтр.

Для каждой длины и стартовой позиции выполняется каскад проверок:

- A. Проверка покрытия: вычисляется глубина MSA (`msadepth`) в окне. Если доля пропусков превышает порог, кандидат отбрасывается.
- B. Контроль вырожденности: отдельно для 5'-головой и 3'-хвоста подсчитывается число позиций, где частота минорного основания превышает параметр `slack`. Это позволяет гибко управлять включением нуклеотидов в IUPAC-консенсус.
- C. Генерация консенсуса: вызывается функция `consensus_degen`, формирующая вырожденную последовательность. Если обратный праймер содержит гэпы, он отбрасывается.
- D. Термодинамическая фильтрация: рассчитываются GC-состав, ΔG и распределение T_m . Кандидат проходит фильтр, только если доверительный интервал T_m полностью попадает в заданный диапазон, а ΔG вторичных структур не ниже порогового значения.

Задача сопряжения праймеров решается функцией `best_pairs`, которая принимает векторы прямых и обратных кандидатов. Алгоритм перебирает пары,

Как и SeqFold.jl, пакет DePPA.jl прошел регистрацию в Julia General Registry, на 62% покрыт юнит-тестами (с использованием Aqua.jl и JET.jl) и интегрирован с Codecov. Документация автоматически генерируется и публикуется на GitHub Pages.

Для интеграции в существующие биоинформатические пайплайны, написанные на Python, в документации пакета представлен раздел, описывающий использование DePPA.jl через библиотеку juliacall, что позволяет вызывать функции дизайна праймеров и расчета ансамблевой термодинамики непосредственно из Python-скриптов без написания обвязок на Julia.

3.3 Выводы по главе 3

В главе описана архитектура и программная реализация разработанного вычислительного инструментария. На основе анализа существующих решений и математических моделей, сформулированных во второй главе, были созданы два пакета на языке Julia:

- A. Разработано вычислительное ядро SeqFold.jl, представляющее собой высокопроизводительную реализацию алгоритмов предсказания вторичной структуры и расчета температуры плавления.
- B. Спроектирован и реализован пакет DePPA.jl для автоматизированного дизайна вырожденных ПЦР-праймеров.
- C. Оба пакета соответствуют современным стандартам экосистемы Julia.

ГЛАВА 4 АПРОБАЦИЯ АЛГОРИТМОВ И АНАЛИЗ ДАННЫХ ВЫСОКОПРОИЗВОДИТЕЛЬНОГО СЕКВЕНИРОВАНИЯ

Целью данной главы является экспериментальная апробация разработанных алгоритмов и программного обеспечения, а также анализ полученных данных высокопроизводительного секвенирования.

Объектом биологической апробации выступили популяции клубеньковых бактерий (ризобий) и ассоциированная с ними почвенная микробиота. Для формирования репрезентативной выборки на экспериментальных участках ВНИИСХМ были отобраны растения трех видов бобовых: люцерны, козлятника и клевера. Сбор биологического материала проводился вручную в период активной вегетации. С

корней каждого растения были собраны корневые клубеньки. Для анализа свободнoживущих популяций отбиралась специфическая почва ризосферы (прикорневая почва) — грунт, находящийся в непосредственной близости от корневой системы и клубеньков. Такой подход позволил получить репрезентативную выборку почвенных ризобий, находящихся под прямым влиянием корневых экссудатов растений, где их концентрация максимальна, в отличие от анализа объемного фонового грунта.

Из полученных индивидуально для каждого растения образцов корневых клубеньков и ризосферной почвы была выделена тотальная ДНК методом, описанным в работе [31], которая далее использовалась в качестве матрицы для ПЦР и подготовки библиотек.

Структура главы организована следующим образом. В разделе 4.1 описывается стратегия *in silico* конструирования и лабораторной валидации наборов праймеров для двухэтапной ПЦР. Раздел 4.2 посвящен шагам фильтрации и денойзинга сырых ридов. В разделе 4.3 проводится сравнительный анализ генетического разнообразия популяций ризобий из двух контрастных субстратов и проверка сформулированной биологической гипотезы.

4.1 *In silico* конструирование и лабораторная валидация наборов праймеров

Успешность ампликонного секвенирования почвенных образцов зависит от качества и специфичности используемых ПЦР-праймеров. В условиях низкой концентрации целевой внеклеточной ДНК (eDNA) в почве, описанной в главе 1, применение одностадийной ПЦР оказывается неэффективным. Для решения этой задачи была разработана стратегия двухэтапной (вложенной) ПЦР с использованием специализированного программного обеспечения DePPA.jl, алгоритмы которого были детально описаны в главе 2, а программная реализация — в главе 3.

Формирование референсных выборок и отбор генов-мишеней. Для конструирования универсальных праймеров была сформирована референсная выборка, состоящая из 67 геномов клубеньковых бактерий, принадлежащих к трем видам: *Sinorhizobium meliloti* (ML, симбионт люцерны), *Neorhizobium galegae* bv. *orientalis* (GO, симбионт козлятника) и *Rhizobium leguminosarum* (TP, симбионт клевера). Все геномы происходят из коллекции нашей лаборатории; часть из них депонирована в базу данных GenBank (BioProject: PRJNA1048330 для ML и PRJNA1049504 для

ТР), тогда как геномы GO на момент проведения работы представляли собой внутренние неопубликованные лабораторные данные.

Поиск консервативных регионов проводился с использованием модуля *simsearch* (Similarity Search) пакета Pannagram [11], который осуществляет поиск гомологичных последовательностей на основе алгоритмов BLAST. В рамках данной работы под *кóровым геномом* (core genome) понималась совокупность генов, ортологи которых достоверно идентифицируются во всех 67 референсных геномах.

Дальнейший отбор мишеней для амплификации осуществлялся в два этапа. Сначала из *кóрового генома* были выделены гены, которые можно однозначно классифицировать как симбиотические (*nodA*, *nodC*, *nifH*) и гены домашнего хозяйства (*folC*, *ftsX*, *recJ*). Симбиотические гены отвечают за ключевые этапы взаимодействия с растением-хозяином: *nodA* и *nodC* участвуют в биосинтезе сигнальных молекул (Nod-факторов), необходимых для инициации симбиоза, а *nifH* кодирует железосодержащий белок (Fe-белок) нитрогеназы, осуществляющий фиксацию атмосферного азота. Гены домашнего хозяйства выполняют конститутивные функции: *folC* участвует в метаболизме фолатов, *ftsX* — в делении клеток, *recJ* — в репарации ДНК. Существенным условием для дальнейшей работы являлась однокопийность отобранных генов. Наличие гена строго в одной копии во всех геномах необходимо для исключения внутримолекулярной конкуренции матриц на этапах ПЦР, что позволяет избежать искажений при количественной оценке разнообразия (альфа- и бета-разнообразие) в последующем анализе данных секвенирования.

Стратегия *in silico* дизайна праймеров для вложенной ПЦР. Для каждого из 6 отобранных генов последовательности, извлеченные из 67 геномов, были объединены в общие множественные выравнивания (MSA). На основе этих выравниваний с помощью пакета DePPA.jl был проведен дизайн праймеров по следующей двухэтапной схеме:

- А. Этап 1: Внешние праймеры. Конструировались на основе общего MSA для всех трех видов. Критерием отбора являлась способность к амплификации максимально широкого спектра вариантов гена с формированием длинного ампликона (до 1000 п.н.). Это необходимо для первичного накопления целевой матрицы из почвенных образцов с низким содержанием eDNA.

В. Этап 2: Внутренние праймеры. Конструировались на основе *тех же самых* общих MSA. Длина целевого ампликона второго этапа строго ограничивалась диапазоном 150–300 п.н., что является требованием платформы Illumina MiSeq. Важным условием являлось строгое вложение внутреннего ампликона в границы внешнего.

Следует особо отметить, что при дизайне как внешних, так и внутренних пар не ставилась задача биоинформатического исключения кросс-контаминации или обеспечения строгой видоспецифичности внутренних праймеров. Дифференциация образцов достигалась на этапе пробоподготовки: внутренние праймеры добавлялись в реакционную смесь только с тем препаратом ДНК (выделенным из клубеньков или ризосферной почвы конкретного растения-хозяина), для которого проводился анализ.

Подбор кандидатов осуществлялся с использованием следующих параметров и ограничений пакета DePPA.jl:

- length_range=17:23 — допустимая длина праймера (п.н.);
- gc_range=40:60 — допустимый диапазон содержания ГЦ-пар (%);
- tm_range=55:60 — целевой диапазон температур плавления (T_m , °C);
- min_delta_g=-5.0 — минимальная допустимая свободная энергия (ΔG , ккал/моль);
- min_msadept=0.75 — минимальная глубина покрытия (доля последовательностей в MSA, содержащих данный регион);
- max_oligo_variants=100 — максимальное число уникальных последовательностей, представляемых одним вырожденным праймером;
- tail_degen_pos=0 — строгий запрет на вырожденные позиции в 3'-хвосте (для обеспечения специфичности инициации синтеза ДНК-полимеразой);
- head_degen_pos=5 — максимальное число вырожденных позиций в 5'-области.

Расчет термодинамических параметров (T_m и ΔG) проводился для условий, максимально приближенных к реальному буферу ПЦР (пресет :pcr в вычислительном ядре SeqFold.jl): концентрация праймера 250 nM , $[Mg^{2+}] = 1.5\text{ mM}$, $[K^+] = 50\text{ mM}$, $[Tris] = 2\text{ mM}$, $[dNTPs] = 0.2\text{ mM}$.

На рис. 4.1 представлен скриншот интерфейса Julia REPL, демонстрирующий отображение расположения внешних и внутренних пар праймеров в координатах выравнивания на примере гена *recJ*.


```

julia> recJ_stage_1_primer_pair
PCR primer pair for 65 seq. MSA, amplicon: 505:962 (458bp)
>_____458bp_____<
|=====1837
|
Forward: ATCGTYACSGTCGAYTGCGG at 505:524
Reverse: GKCCVAKCAGGAGCCGATG at 941:962
Tm: 58.9±0.0 °C

julia> recJ_stage_2_primer_pair
PCR primer pair for 65 seq. MSA, amplicon: 571:843 (273bp)
>___273bp___<
|=====1837
|
Forward: GAYGTGTSGTCATCGAYCAC at 571:591
Reverse: TARGCVCGATTGAGVCCCT at 825:843
Tm: 51.3±0.0 °C

```

Рис.4.1. Интерфейс Julia REPL, отображающий расположение пар праймеров для гена *recJ* (длина выравнивания 1837 п.н.). Внешняя пара праймеров (этап 1) формирует ампликон длиной 458 п.н., внутри которого локализованы сайты связывания внутренних праймеров (этап 2), формирующих ампликон 273 п.н., адаптированный для секвенирования.

Сравнительный *in silico* анализ: ансамблевой и консенсусный подходы.

Для обоснования необходимости использования ансамблевой термодинамики было проведено сравнительное моделирование на примере множественного выравнивания гена *nodC*. Для 383 валидных пар праймеров, сконструированных пакетом DePPA.jl, были рассчитаны термодинамические профили двумя способами: (1) *Ансамблевой подход* — расчет распределения T_m для всего пула уникальных вариантов (реализовано в DePPA.jl); (2) *Консенсусный подход* — метод, при котором для каждого окна MSA формируется единственная невырожденная последовательность путем выбора наиболее частотного нуклеотида (мажорный консенсус), для которой затем рассчитывается T_m .

Результаты сравнения представлены в табл. 4.1.

Таблица 4.1

Сравнение термодинамических профилей пар праймеров для гена *nodC* ($n = 383$)

Метрика	DePPA	Консенсусный
$\bar{T}_m$ (Forward), °C	54.9 ± 1.5	65.5 ± 2.1
$\bar{T}_m$ (Reverse), °C	55.6 ± 2.0	64.4 ± 4.0
$\Delta\bar{T}_m$ (F – R), °C	1.9 ± 1.2	4.0 ± 2.5

Анализ табл. 4.1 выявляет ограничения консенсусного подхода при работе с вырожденными праймерами. Во-первых, консенсусный подход систематически завышает температуру плавления в среднем на 10°C. Это происходит потому, что мажорный консенсус игнорирует минорные варианты последовательностей

(которые физически присутствуют в реакционной смеси и часто содержат менее стабильные А-Т пары), формируя «химерную» последовательность с искусственно высокой термодинамической стабильностью. Настройка ПЦР на температуру отжига, диктуемую консенсусом ($\sim 65^\circ\text{C}$), привела бы к тому, что реальные молекулы пула (имеющие ансамблевую $T_m \approx 55^\circ\text{C}$) не смогли бы эффективно отжигаться на матрице. Во-вторых, консенсусный подход демонстрирует высокую разбалансированность пар праймеров: средняя разница температур плавления между прямым и обратным праймерами составляет $\Delta T_m \approx 4.0^\circ\text{C}$ (с разбросом до 8.7°C). В условиях ПЦР такая асимметрия приводит к тому, что один из праймеров отжигается неэффективно, что вызывает накопление одноцепочечных продуктов и резкое падение выхода целевого двуцепочечного ампликона. Напротив, разработанный ансамблевый подход гарантирует баланс пары ($\Delta T_m < 2^\circ\text{C}$), что обеспечивает синхронный отжиг и экспоненциальное накопление продукта, минимизируя ПЦР-смещение.

Лабораторная валидация и оптимизация режимов амплификации. Изначально для ряда генов было синтезировано несколько кандидатных прямых и обратных праймеров. Однако по результатам скрининговых испытаний, в которых все пары с успехом протестировались на чистой геномной ДНК референсных штаммов и дали на фореze продукт ожидаемой длины, для дальнейшей работы были отобраны наиболее эффективные комбинации.

В качестве матрицы для оптимизации ПЦР использовалась ДНК, выделенная из описанных выше образцов. Для первого раунда вложенной ПЦР был разработан модифицированный протокол, отличающийся от стандартного режима второго раунда. Первый цикл амплификации проводился с удлиненными временными параметрами: денатурация при 95°C (90 с), отжиг при 50°C (120 с), элонгация при 72°C (60 с). За ним следовали 34 цикла стандартного режима: денатурация при 95°C (30 с), отжиг при 55°C (30 с), элонгация при 72°C (60 с). Удлинение первого цикла необходимо для обеспечения эффективного отжига праймеров на сложной почвенной матрице с экстремально низкой концентрацией целевой ДНК: повышенное время отжига компенсирует кинетические ограничения связывания вырожденных праймеров с редкими мишенями в присутствии избытка неспецифической ДНК.

Обоснование минимизации артефактов вложенной ПЦР. Как обговаривалось в гл. 1.2, двухэтапная амплификация склонна к генерации химер и ошибок, искажающих оценку альфа-разнообразия [20]. В данной работе этот риск подавлен комплексным подходом: во-первых, строгим ограничением числа циклов

предотвращается выход реакции на плато и истощение реагентов [21]; во-вторых, применение термодинамически сбалансированных праймеров (DePPA.jl) обеспечивает синхронный отжиг и минимизирует образование неполных удлинений цепи – главных предшественников химер; в-третьих, конвейер обработки на базе DADA2 [5] с алгоритмом `removeBimeraDeNovo` математически отделяет истинные ASV от артефактов амплификации и секвенирования. В результате итоговый набор последовательностей очищен от систематических искажений, характерных для вложенной ПЦР.

Успешность амплификации подтверждали методом агарозного электрофореза по следующим критериям: единственная полоса ожидаемого размера, отсутствие праймер-димеров и неспецифичных продуктов. На рис. 4.2 представлены результаты валидации для 6 целевых генов из образцов почвы, демонстрирующие формирование четких ампликонов целевой длины во втором раунде ПЦР.

Анализ продуктов первого раунда (рис. 4.2а) выявляет характерные особенности амплификации из почвенных образцов: вместо четких узких полос наблюдаются размытые полосы (т.н. «шмеры») неспецифичной амплификации на дорожках геля, что было ожидаемо для первого этапа вложенной ПЦР при работе с комплексной почвенной матрицей. Примечательно, что на дорожке гена *nodA* целевой продукт визуально не детектируется, несмотря на то, что положительный контроль (амплификация *nodA* из очищенной геномной ДНК референсного штамма) демонстрирует успешную работу праймерной пары. Это свидетельствует о том, что концентрация матрицы *nodA* в почвенном образце находится ниже порога визуальной фиксации, однако достаточна для последующей специфической амплификации.

Результаты второго раунда (рис. 4.2б) подтверждают эффективность стратегии вложенной ПЦР: все 6 генов, включая *nodA*, амплифицируются с формированием четких полос ожидаемого размера (153–273 п.н.) без серьезных неспецифических продуктов. Это демонстрирует, что первый раунд, несмотря на отсутствие визуализируемого продукта для некоторых генов, выполняет свою ожидаемую функцию первичного увеличения концентрации матрицы, делая возможным успешную амплификацию на втором этапе.

Формирование библиотек для высокопроизводительного секвенирования. По итогам лабораторной валидации был сформирован финальный набор из 12 пар праймеров: 6 внешних и 6 внутренних пар.




Рис.4.2. Результаты агарозного электрофореза продуктов вложенной ПЦР при амплификации 6 генов из препаратов почвенной ДНК (*S. meliloti*, симбионт люцерны). **а** — первый раунд (внешние универсальные праймеры, ампликон 300–841 п.н.); видны размытые шмеры неспецифической амплификации, на дорожке *nodA* целевой продукт визуально не детектируется; **б** — второй раунд (внутренние праймеры, ампликон 153–273 п.н.); все 6 генов амплифицированы успешно. Молекулярный маркер 100 bp DNA Ladder (полосы: 100, 200, ..., 1000 п.н.).

Амплификация проводилась для ДНК, выделенной из двух контрастных субстратов: ризосферной почвы (свободноживущие популяции) и корневых клубеньков (симбиотические популяции) для всех трех видов растений. Таким образом, экспериментальный дизайн включал 6 генов $\times$ 3 вида $\times$ 2 субстрата = 36 уникальных комбинаций. Ампликоны были очищены, доведены до единой концентрации и переданы для секвенирования на платформе Illumina MiSeq на базе ЦКП «Геномные технологии, протеомика и клеточная биология» ФГБНУ ВНИИСХМ. Лист подготовки проб представлен в приложении 1.

Таким образом, комбинация пангеномного анализа и разработанного ПО DePPA.jl позволила сформировать набор вложенных пар праймеров и успешно пройти этап лабораторной валидации, преодолев кинетические ограничения амплификации из сложной почвенной матрицы. Итогом проделанной работы стала подготовка 36 библиотек для высокопроизводительного секвенирования, что создало эмпирическую базу для этапа биоинформатической фильтрации и денойзинга, описываемого в разделе 4.2.

4.2 Алгоритмы биоинформатической фильтрации и денойзинга данных секвенирования

Полученные массивы сырых ридов требуют многоэтапной биоинформатической обработки для перехода к таблицам вариантов ASV с разрешением до

одного нуклеотида. В отличие от кластеризации в OTU с порогом сходства 97%, алгоритмы денойзинга сохраняют тонкую генетическую вариабельность. Ниже описаны этапы обработки 36 библиотек ампликонного секвенирования.

Первичная обработка и контроль качества ридов. Удаление последовательностей ПЦР-праймеров осуществлялось программой Cutadapt [17]. Для корректного тримминга вырожденных праймеров (содержащих IUPAC-коды) допустимый уровень несовпадений был установлен на уровне 15%, что учитывает термодинамическую гетерогенность пулов.

Качество секвенирования оценивалось по шкале Phred (Q), в соответствии с которой вероятность ошибки в позиции i рассчитывается как:

$$P_{\text{err}}(i) = 10^{-Q_i/10}. \quad (4.1)$$

Параметры обрезки ридов (truncLen) выбирались на основе агрегированного профиля качества (25-й процентиль) при условии, что качество не падает ниже Q_{30} ($P_{\text{err}} = 0.001$), а сумма длин обрезанных прямых и обратных ридов обеспечивала минимальное перекрытие для их последующей сшивки (рис. 4.3).

Алгоритмы денойзинга и удаления артефактов. Для разделения истинных биологических последовательностей и ошибок секвенирования применялся алгоритм DADA2 [5].

Фильтрация ридов. Отбрасывались риды с ожидаемым количеством ошибок $EE > 2$, а также содержащие неоднозначные нуклеотиды ($\text{maxN} = 0$). Ожидаемое количество ошибок рассчитывается как сумма вероятностей ошибок по всем позициям рида длиной L :

$$EE = \sum_{i=1}^L P_{\text{err}}(i) = \sum_{i=1}^L 10^{-Q_i/10}. \quad (4.2)$$

Обучение параметрической модели ошибок. Интенсивность ошибок λ_{ji} , с которой из истинной последовательности j образуется прочтение i , моделируется как произведение вероятностей замен между выровненными нуклеотидами:

$$\lambda_{ji} = \prod_{l=1}^L p(j(l) \rightarrow i(l), q_i(l)), \quad (4.3)$$

где $p(j(l) \rightarrow i(l), q_i(l))$ — вероятность перехода от нуклеотида $j(l)$ к $i(l)$ при данном качестве $q_i(l)$. Для ускорения вычислений и исключения некорректных выравниваний применяются эвристические фильтры (kmer-расстояние и полосное




Рис.4.3. Агрегированный профиль качества ридов для гена *folC*. **Верхний график** — прямые риды, **нижний** — обратные риды. Голубая область — интервал между 25-м и 75-м перцентилями качества; синяя сплошная линия — медиана качества; красная пунктирная линия — среднее качество; зеленая пунктирная линия — доля образцов, представленных на данной позиции. Горизонтальная красная пунктирная линия обозначает пороговое значение $Q = 30$.

выравнивание). Параметры модели оцениваются итеративно (ЕМ-алгоритм) независимо для прямых и обратных ридов каждой комбинации «ген/растение-хозяин».

Алгоритм денойзинга. Разделение последовательностей основано на методе партиционного правдоподобия. p_A -значение представленности p_A оценивает вероятность того, что наблюдаемое число ридов a_i не может быть объяснено ошибками секвенирования более распространенной последовательности j (число ридов n_j). При условии пуассоновского распределения ошибок, p_A определяется как:

$$p_A(j \rightarrow i) = \frac{1}{1 - \rho_{\text{pois}}(n_j \lambda_{ji}, 0)} \sum_{a=a_i}^{\infty} \rho_{\text{pois}}(n_j \lambda_{ji}, a), \quad (4.4)$$

где ρ_{pois} — функция вероятности распределения Пуассона. Последовательности с низким p_A (с поправкой Бонферрони) формируют новые кластеры (истинные ASV).




Рис.4.4. Параметрическая модель ошибок прямых прочтений для гена *recJ* (образец GO). Точки показывают наблюдаемые частоты ошибок в зависимости от качества Phred. Сплошная кривая — аппроксимация методом loess, используемая для параметризации модели.

Синглтоны (последовательности, встречающиеся однократно) алгоритмически не формируют независимые кластеры, так как их p_A условно равно 1.

Сшивка и удаление химер. После отдельного денойзинга риды сшивались (`mergePairs`) с требованием точного совпадения в зоне перекрытия (минимум 12 п.н., 0 несовпадений). Далее алгоритмом `removeBimeraDenovo` (метод `consensus`) удалялись химеры — последовательности, которые без несовпадений собираются из двух более распространенных родительских ASV.

Построение филогенетических деревьев. Множественное выравнивание полученных ASV выполнялось программой MAFFT [16]. Филогенетические деревья строились методом присоединения соседей (Neighbor-Joining, NJ) [33] на основе матрицы попарных p -расстояний. Визуализация деревьев и интеграция филогенетической информации с данными об обилии ASV проводились в среде R с

использованием пакета ggtree [9], одно из построенных деревьев представлено на рис. 4.5.

Применение описанных алгоритмов позволило устранить системные ошибки секвенирования и ПЦР-артефакты. В результате для каждого из 36 образцов были получены высокоточные таблицы ASV, которые далее использовались для анализа генетического разнообразия в разделе 4.3.

4.3 Сравнительный анализ генетического разнообразия и проверка биологической гипотезы

Целью данного раздела является проверка сформулированной во введении биологической гипотезы о различиях в генетическом разнообразии популяций ризобий, находящихся в двух контрастных экологических нишах: в ризосферной почве (свободноживущие формы) и в корневых клубеньках (симбиотические формы). Анализ проводился на основе таблиц ASV, полученных в результате многоэтапной биоинформатической обработки (включая обрезку праймеров, вероятностный денойзинг и удаление химер) 36 библиотек с использованием среды R [29] и сторонних пакетов [4; 6; 18; 38—41].

Анализ интегральных метрик: альфа- и бета-разнообразие. Для оценки внутриобразцового богатства (альфа-разнообразие) использовались метрики наблюдаемого богатства (Observed Richness) и индекса Шеннона (Shannon). В связи с неравномерной глубиной секвенирования библиотек, таблицы ASV были нормализованы методом разрежения (rarefaction) до минимальной глубины секвенирования среди валидных образцов (с числом прочтений > 0) для каждого гена. Процедура выполнялась с фиксированным зерном генератора случайных чисел без возвращения (`replace = FALSE`) и автоматическим удалением вариантов, потерявших все прочтения (`trimOTUs = TRUE`).

Анализ показал наличие устойчивого тренда: для всех шести исследованных генов разнообразие в почвенных образцах превышало таковое в клубеньках. Кратность изменений (Fold Change, почва/клубенек) составляла от 2.2 до 4.4. Однако статистическая проверка с помощью рангового критерия Уилкоксона не выявила статистически значимых различий на стандартном уровне $\alpha = 0.05$ ($p > 0.05$ для всех генов). Необходимо подчеркнуть, что отсутствие статистической значимости в данном случае является следствием ограниченной статистической мощности при малом объеме выборки $n = 3$, где n – количество биологических повторностей, что




Рис.4.5. Дерево, и тепловая карта, построенные из объединённой по трём видам растений и обоим субстратам таблицы ASV для гена *recJ*. Для построения графика были отфильтрованы ASV с совокупной представленностью по всем столбцам таблицы меньше 15.

не позволяет строго отвергнуть нулевую гипотезу вне зависимости от величины наблюдаемого эффекта.

На рис. 4.6 представлены боксплоты альфа-разнообразия для всех шести исследованных генов. Визуальный анализ подтверждает наличие тренда к более высокому разнообразию в почвенных популяциях для обеих метрик. Количественные значения средних, кратности изменений и достигнутых уровней значимости приведены в табл. 4.2.




Рис.4.6. Альфа-разнообразие популяций ризобий в почве (soil, оранжевый) и клубеньках (nod, синий) для шести генов. Формы точек отражают растение-хозяина: ML (люцерна), GO (козлятник), TP (клевер). Для всех генов наблюдается тренд к более высокому разнообразию в почвенных образцах.

Результаты анализа бета-разнообразия (PCoA-ординации и статистика PERMANOVA), не выявившие статистически значимого разделения сообществ по фактору субстрата, представлены в приложении 2 (рис. ПП2.1, табл. ПП2.1). Отсутствие кластеризации указывает на то, что доминантные ASV клубеньков присутствуют и в почве. Однако для проверки гипотезы о наличии специфического резервуара уникальных аллелей классических интегральных метрик оказалось недостаточно, и был применен анализ пересечения уникальных генетических пулов.

Таблица 4.2

Сводная таблица альфа-разнообразия (почва против клубенька)

Ген	Метрика	Почва	Клубенок	Fold Change	p-value
<i>nodA</i>	Observed	145.7	66.0	2.21	0.081
	Shannon	4.56	3.86	1.18	0.081
<i>nodC</i>	Observed	41.3	13.0	3.18	0.077
	Shannon	3.17	2.23	1.42	0.081
<i>nifH</i>	Observed	47.0	10.7	4.39	0.081
	Shannon	3.07	1.82	1.69	0.081
<i>folC</i>	Observed	53.0	13.0	4.08	0.383
	Shannon	2.85	1.34	2.13	0.190
<i>ftsX</i>	Observed	112.7	25.3	4.45	0.081
	Shannon	3.51	1.91	1.84	0.081
<i>recJ</i>	Observed	108.0	26.3	4.11	0.081
	Shannon	4.24	2.98	1.42	0.081

Анализ уникальных ASV: концепция резервуара разнообразия и экологического фильтра. Поскольку интегральные метрики альфа-разнообразия не учитывают структурное сходство сообществ, для проверки гипотезы о наличии специфического резервуара уникальных аллелей был проведен анализ пересечения пулов ASV (диаграммы Венна) между почвенными и клубеньковыми образцами для каждого гена. Данный подход позволил идентифицировать и количественно оценить долю генетических вариантов, эксклюзивно относящихся к одному из рассматриваемых субстратов.

Для формализации селективного давления был введен *Фактор обогащения* (Enrichment Factor, EF) — отношение количества уникальных ASV, встречающихся только в почве, к количеству уникальных ASV, встречающихся только в клубеньках. Данный показатель отражает степень потери разнообразия при переходе бактерии от свободноживущего состояния к симбиозу. Результаты представлены в табл. 4.3.

Визуализация пересечения пулов уникальных ASV между почвенными и клубеньковыми образцами представлена на рис. 4.7. Диаграммы Венна демонстрируют выраженное преобладание уникальных вариантов в почве, особенно для симбиотических генов.

Для наглядного сопоставления строгости селективного барьера между двумя группами генов на рис. 4.8 представлен обобщающий график фактора обогащения. Полученные результаты (базовый фильтр для НК-генов $\approx 5.5\times$ и усиленный симбиотический барьер $\approx 11.1\times$) иллюстрируют различия в степени потери уникального

Таблица 4.3

Сравнительный анализ уникальных пулов ASV (почва против клубенька)

Ген	Тип	Уник. в почве	Уник. в клубеньках	Общие	EF
<i>nodA</i>	Симбиотические	204	21	169	9.71
<i>nodC</i>	Симбиотические	72	6	28	12.00
<i>nifH</i>	Симбиотические	93	8	23	11.63
<i>folC</i>	Дом. хозяйства	133	20	13	6.65
<i>ftsX</i>	Дом. хозяйства	269	56	18	4.80
<i>recJ</i>	Дом. хозяйства	269	53	27	5.08




Рис.4.7. Диаграммы Венна, отражающие пересечение пулов ASV между почвой (soil) и клубеньками (nod) для шести генов. Для симбиотических генов (*nodA*, *nodC*, *nifH*) размер уникального почвенного пула многократно превышает таковой для клубеньков, что подтверждает концепцию «резервуара разнообразия».

разнообразия между группами генов, что позволяют говорить о двухкомпонентной структуре экологического фильтра:




Рис.4.8. Фактор обогащения уникальными ASV для генов домашнего хозяйства (оранжевый) и симбиотических генов (синий). Пунктирные линии обозначают средние значения по группам: НК-гены ($\approx 5.5\times$) и симбиотические гены ($\approx 11.1\times$), что количественно подтверждает двухкомпонентность характера отбора при формировании симбиоза.

Полученные данные согласуются с концепцией почвенного резервуара симбиотического разнообразия [24]. Согласно этой модели, свободноживущие популяции ризобий в ризосфере представляют собой эволюционный резервуар, где симбиотические гены, локализованные на мобильных генетических элементах (symICE, мегаплазмиды), постоянно рекомбинируют и накапливаются в виде обширного пула аллельных вариантов. Переход к симбиозу (инфицирование клубенька) выступает в роли специфического экологического фильтра, который осуществляет направленную селективную редукцию этого резервуара.

Анализ табл. 4.3 выявляет паттерн снижения разнообразия, который может быть описан моделью экологического фильтра с двумя компонентами. Переход бактерий из свободноживущего состояния в почве к симбиозу в клубеньке сопровождается последовательным наложением двух факторов редукции:

- А. Фильтр пространственной изоляции (эффект основателя). Формирование клубенька начинается с проникновения ограниченного числа бактерий через корневой волосок, что создает «бутылочное горлышко». Данный

фактор снижает разнообразие по всем генам независимо от их функции. Количественно этот эффект может быть оценен по генам домашнего хозяйства (*folC*, *ftsX*, *recJ*), на которые растение не оказывает направленного отбора. Усредненный фактор обогащения для НК-генов составляет $EF_{iso} \approx 5.5$, что отражает потерю уникальных аллелей за счет эффекта основателя.

- В. Фильтр специфического симбиотического отбора. Поверх эффекта изоляции растение-хозяин осуществляет активный молекулярный отбор бактерий по эффективности симбиоза (распознавание Nod-факторов, контроль фиксации азота). Этот фильтр дополнительно воздействует на мобильные симбиотические гены (*nodA*, *nodC*, *nifH*). Для симбиотических генов общий фактор обогащения достигает $EF_{sym} \approx 11.1$.

Таким образом, редукция разнообразия симбиотических генов может быть представлена как произведение двух факторов:

$$EF_{sym} \approx EF_{iso} \times EF_{spec}, \quad (4.5)$$

где множители $EF_{iso} \approx 5.5$ (эффект изоляции), $EF_{spec} \approx 2.0$ (вклад специфического отбора со стороны растения) получены эмпирически в ходе данной работы. Полученные данные количественно подтверждают, что клубенок выступает не как пассивноеместилище почвенных бактерий, а как активный селективный барьер, который примерно вдвое ($EF_{spec} \approx 2$) сильнее ограничивает генетическое разнообразие симбиотических генов по сравнению с генами домашнего хозяйства.

4.4 Выводы по главе 4

В данной главе была проведена экспериментальная апробация разработанных алгоритмов и выполнена проверка сформулированной биологической гипотезы. Основные результаты главы заключаются в следующем:

- А. С помощью пакета DePPA.jl успешно сконструированы наборы вырожденных праймеров для двухэтапной вложенной ПЦР шести генов (трех симбиотических и трех генов домашнего хозяйства). Лабораторная валидация подтвердила, что разработанный *in silico* подход позволяет преодолеть сложности амплификации из сложной почвенной матрицы с экстремально низкой концентрацией eDNA и подготовить 36 библиотек для высокопроизводительного секвенирования.

- В. Проведенное *in silico* сравнение продемонстрировало, что консенсусный подход, в отличие от разработанного ансамблевого, систематически завышает температуру плавления вырожденных праймеров и формирует термодинамически несбалансированные пары, что делает его неприменимым для минимизации ПЦР-смещений.
- С. Применен конвейер биоинформатической обработки на базе вероятностной модели DADA2, позволивший устранить системные ошибки секвенирования и артефакты ПЦР, и получить таблицы ASV с разрешением до одного нуклеотида.
- Д. Сравнительный анализ генетического разнообразия популяций ризобий в двух контрастных экологических нишах подтвердил сформулированную в работе биологическую гипотезу. Анализ пересечения уникальных ASV и введенный показатель «фактора обогащения» (EF) позволили количественно описать двукомпонентную модель экологического фильтра.
- Е. Установлено, что переход бактерий из свободноживущего состояния в симбиоз сопровождается последовательным наложением эффекта пространственной изоляции и специфического молекулярного отбора со стороны растения-хозяина. Показано, что почвенные популяции формируют обширный резервуар уникальных аллелей симбиотических генов, который при инфицировании растения проходит через селективный барьер, приводящий к снижению разнообразия симбиотических генов по сравнению с генами домашнего хозяйства.

ЗАКЛЮЧЕНИЕ

В рамках данной выпускной квалификационной работы была решена научно-техническая задача, заключающаяся в разработке высокопроизводительного программного обеспечения для конструирования вырожденных ПЦР-праймеров с учетом ансамблевой термодинамики, а также проведена его экспериментальная апробация при анализе популяций почвенных ризобий.

Основные результаты работы, соответствующие поставленным задачам, заключаются в следующем:

- А. Проведен критический анализ существующего программного обеспечения для дизайна ПЦР-праймеров. Выявлено фундаментальное ограничение современных инструментов (Primer3, HYDEN, OpenPrimeR и др.), заключающееся в игнорировании физико-химической гетерогенности пулов вырожденных олигонуклеотидов. Установлено, что опора на усредненные консенсусные последовательности или комбинаторные модели несовпадений приводит к ПЦР-смещениям и потере редких таксонов при анализе сложных почвенных сообществ.
- В. Разработан математический аппарат и алгоритмы оценки статистического распределения термодинамических параметров (температуры плавления T_m и свободной энергии Гиббса ΔG) для смесей вырожденных олигонуклеотидов. Сформулированы математические критерии фильтрации кандидатов, включающие контроль доверительных интервалов T_m , доли расплавленных молекул и её дисперсии, что позволяет на этапе *in silico* минимизировать неравенство эффективностей отжига различных вариантов праймера и обеспечить репрезентативную амплификацию.
- С. Осуществлена программная реализация разработанных алгоритмов на языке Julia. Создано высокопроизводительное вычислительное ядро SeqFold.jl, в котором устранены критические ошибки расчета ионных поправок, присутствовавшие в исходном Python-коде, и достигнут многократный прирост скорости вычислений. На его основе разработан пакет DePPA.jl для автоматизированного дизайна праймеров по множественным выравниваниям. Оба пакета обладают модульной архитектурой, прошли регистрацию в Julia General Registry доступны научному сообществу под свободными лицензиями.

- D. Проведена полная экспериментальная апробация разработанного ПО. Сконструированы наборы вырожденных праймеров для 6 генов, успешно амплифицированы и секвенированы 36 библиотек. *In silico* сравнение доказало, что классический консенсусный подход систематически завышает температуру плавления вырожденных праймеров. Проведённая биоинформатическая обработка данных и анализ фактора обогащения подтвердили сформулированную биологическую гипотезу: свободноживущие популяции в почве формируют обширный резервуар уникальных аллелей, который, при входе в симбиотические отношения с растением, проходит через строгий двухкомпонентный экологический фильтр.

Практические предложения и рекомендации

На основе полученных результатов сформулированы следующие рекомендации, направленные на улучшение методологии анализа почвенной микробиоты и конструирования нуклеиновых кислот:

- A. Для анализа высоковариабельных генов в сложных почвенных образцах рекомендуется применять разработанный пакет DePPA.jl, обеспечивающий строгий термодинамический контроль пулов олигонуклеотидов. Использование ансамблевого подхода позволяет нивелировать ПЦР-смещения и сохранять редкие аллели, которые иначе могут быть утеряны.
- B. При дизайне вырожденных праймеров необходимо отказаться от расчета T_m для мажорного консенсуса. В качестве обязательных метрик качества следует внедрить оценку распределения температур плавления и дисперсии доли расплавленных молекул (σ_f^2), что гарантирует синхронный отжиг всех вариантов праймера и баланс прямой и обратной пар.
- C. Для оценки разнообразия почвенных симбионтов рекомендуется использовать стратегию вложенной ПЦР в комбинации с вероятностным денойзингом (DADA2). Это позволяет преодолеть ограничения, связанные с экстремально низкой концентрацией целевой eDNA в почве, и отделить истинные биологические последовательности от ПЦР-артефактов.
- D. При экологическом моделировании симбиозов для корректной оценки действия экологических фильтров рекомендуется разделять анализ на симбиотические гены и гены домашнего хозяйства. Это позволяет количественно разграничить эффект основателя (бутылочного горлышка) и специфический молекулярный отбор растения-хозяина.

Е. Для интеграции в существующие биоинформатические пайплайны разработанные инструменты могут быть подключены к скриптам на языке Python или R посредством интерфейса `juliacall`, что обеспечивает гибкость и высокую производительность вычислений без необходимости переписывания всей аналитической инфраструктуры.

Автор выражает глубокую благодарность своему научному руководителю за постановку задачи, внимание к работе и ценные научные консультации. Также автор благодарит коллег из лаборатории за помощь в отборе биологического материала, проведении ПЦР-амплификации и обсуждении биологических результатов. Автор выражает благодарность всем оказавшим поддержку и помощь, на всех этапах написания работы и допуска к её защите. Отдельная благодарность сотрудникам ЦКП «Геномные технологии, протеомика и клеточная биология» ФГБНУ ВНИИСХМ за проведение высокопроизводительного секвенирования и техническую поддержку на этапе подготовки библиотек.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Bezlepky A.* DePPA.jl: Degenerate Primer Pair Assembler / <https://github.com/phlaster/DePPA.jl>. — 2026.
2. *Bezlepky A.* SeqFold.jl: Nucleic acid folding and melting temperature calculation / <https://github.com/phlaster/SeqFold.jl>. — 2025.
3. *Biomatters.* Geneious Prime / <https://www.geneious.com>. — 2024. — (Version 2024.0.5).
4. Biostrings: Efficient manipulation of biological strings / Н. Pagès [и др.]. — 2025. — DOI 10.18129/B9.bioc.Biostrings. — URL: <https://bioconductor.org/packages/Biostrings>; (R package version 2.78.0).
5. DADA2: High-resolution sample inference from Illumina amplicon data / B. J. Callahan [и др.] // *Nature Methods*. — 2016. — Т. 13, № 7. — С. 581—583. — DOI 10.1038/nmeth.3869. — URL: <https://doi.org/10.1038/nmeth.3869>.
6. dplyr: A Grammar of Data Manipulation / Н. Wickham [и др.]. — 2026. — DOI 10.32614/CRAN.package.dplyr. — URL: <https://CRAN.R-project.org/package=dplyr>; (R package version 1.2.0).
7. *Fulghum B., Tanker S. H., White Richard Allen I.* DeGenPrime provides robust primer design and optimization unlocking the biosphere // *Bioinformatics Advances*. — 2024. — Т. 4, № 1. — vbae044. — DOI 10.1093/bioadv/vbae044. — eprint: <https://academic.oup.com/bioinformaticsadvances/article-pdf/4/1/vbae044/57185934/vbae044.pdf>. — URL: <https://doi.org/10.1093/bioadv/vbae044>.
8. *Gaby J. C., Buckley D. H.* A Comprehensive Evaluation of PCR Primers to Amplify the *nifH* Gene of Nitrogenase // *PLOS ONE*. — 2012. — Т. 7, № 7. — С. 1—12. — DOI 10.1371/journal.pone.0042149. — URL: <https://doi.org/10.1371/journal.pone.0042149>.
9. ggtree: an r package for visualization and annotation of phylogenetic trees with their covariates and other associated data / G. Yu [и др.] // *Methods in Ecology and Evolution*. — 2017. — Т. 8, № 1. — С. 28—36. — DOI <https://doi.org/10.1111/2041-210X.12628>. — eprint: <https://besjournals.onlinelibrary.wiley.com/doi/pdf/10.1111/2041-210X.12628>. — URL: <https://besjournals.onlinelibrary.wiley.com/doi/abs/10.1111/2041-210X.12628>.
10. *Guo J., Starr D., Guo H.* Classification and review of free PCR primer design software // *Bioinformatics*. — 2021. — Т. 36, № 22/23. — С. 5263—5268. — DOI 10.1093/bioinformatics/btaa910. — eprint: <https://academic.oup.com/bioinformatics/>

article-pdf/36/22-23/5263/50716041/btaa910.pdf. — URL: <https://doi.org/10.1093/bioinformatics/btaa910>.

11. *Igolkina A. A., Bezlepsy A. D., Nordborg M.* Pannagram: unbiased pangenome alignment and the Mobilome calling // bioRxiv. — 2025. — DOI 10.1101/2025.02.07.637071. — eprint: <https://www.biorxiv.org/content/early/2025/02/08/2025.02.07.637071.full.pdf>. — URL: <https://www.biorxiv.org/content/early/2025/02/08/2025.02.07.637071>.

12. *Jarman S.* Amplicon: Software for designing PCR primers on aligned DNA sequences // Bioinformatics (Oxford, England). — 2004. — T. 20. — C. 1644—5. — DOI 10.1093/bioinformatics/bth121.

13. Julia: A Fresh Approach to Numerical Computing / J. Bezanson [и др.] // CoRR. — 2014. — T. abs/1411.1607. — arXiv: 1411.1607. — URL: <http://arxiv.org/abs/1411.1607>.

14. *Koressarra T., Remm M.* Enhancements and Modifications of Primer Design Program Primer3 // Bioinformatics. — 2007. — T. 23. — C. 1289—1291. — DOI 10.1093/bioinformatics/btm091. — URL: <https://doi.org/10.1093/bioinformatics/btm091>.

15. *Linhart C., Shamir R.* The Degenerate Primer Design Problem: Theory and Applications // Journal of Computational Biology. — 2005. — T. 12, № 4. — C. 431—456. — DOI 10.1089/cmb.2005.12.431.

16. MAFFT: a novel method for rapid multiple sequence alignment based on fast Fourier transform / K. Katoh [и др.] // Nucleic Acids Research. — 2002. — T. 30, № 14. — C. 3059—3066. — DOI 10.1093/nar/gkf436. — eprint: <https://academic.oup.com/nar/article-pdf/30/14/3059/9488148/gkf436.pdf>. — URL: <https://doi.org/10.1093/nar/gkf436>.

17. *Martin M.* Cutadapt removes adapter sequences from high-throughput sequencing reads // Next Generation Sequencing Data Analysis. — 2011. — T. 17, № 1. — pp. 10—12. — DOI 10.14806/ej.17.1.200.

18. *McMurdie P. J., Holmes S.* phyloseq: An R Package for Reproducible Interactive Analysis and Graphics of Microbiome Census Data // PLOS ONE. — 2013. — T. 8, № 4. — e61217. — DOI 10.1371/journal.pone.0061217. — URL: <https://doi.org/10.1371/journal.pone.0061217>.

19. Modeling the Amplification of Immunoglobulins through Machine Learning on Sequence-Specific Features / M. Döring [и др.] // Scientific Reports. — 2019. — T. 9, № 1. — C. 1—11.

20. Nested PCR Biases in Interpreting Microbial Community Structure in 16S rRNA Gene Sequence Datasets / G. Yu [и др.] // PLoS ONE. — 2015. — Т. 10, № 7. — e0132253. — DOI 10.1371/journal.pone.0132253. — URL: <https://doi.org/10.1371/journal.pone.0132253>.
21. Nested PCR to optimize *rpoB* metabarcoding for low-concentration and host-associated bacterial DNA / L. Leclerc [и др.] // Microbiology Spectrum. — 2025. — Т. 13, № 9. — e01417—25. — DOI 10.1128/spectrum.01417-25. — eprint: <https://journals.asm.org/doi/pdf/10.1128/spectrum.01417-25>. — URL: <https://journals.asm.org/doi/abs/10.1128/spectrum.01417-25>.
22. Next-generation sequencing approaches for soil microbiome research / D. A. Reznikova [и др.] // Frontiers in Soil Science. — 2026. — Т. Volume 5 —2025. — DOI 10.3389/fsoil.2025.1706999. — URL: <https://www.frontiersin.org/journals/soil-science/articles/10.3389/fsoil.2025.1706999>.
23. openPrimeR for multiplex amplification of highly diverse templates / C. Kreer [и др.] // Journal of Immunological Methods. — 2020. — C. 112752. — URL: <https://bioconductor.org/packages/release/bioc/html/openPrimeR.html>.
24. Pangenome Evolution Reconciles Robustness and Instability of Rhizobial Symbiosis / A. J. Weisberg [и др.] // mBio. — 2022. — Т. 13, № 3. — e00074—22. — DOI 10.1128/mbio.00074-22. — eprint: <https://journals.asm.org/doi/pdf/10.1128/mbio.00074-22>. — URL: <https://journals.asm.org/doi/abs/10.1128/mbio.00074-22>.
25. Primaclade—a flexible tool to find conserved PCR primers across multiple species / M. D. Gadberry [и др.] // Bioinformatics. — 2005. — Т. 21, № 7. — C. 1263—1264. — DOI 10.1093/bioinformatics/bti134. — (Epub 2004 Nov 11).
26. Primer-BLAST: A tool to design target-specific primers for polymerase chain reaction / J. Ye [и др.] // BMC Bioinformatics. — 2012. — Т. 13, № 1. — C. 134. — DOI 10.1186/1471-2105-13-134. — URL: <https://doi.org/10.1186/1471-2105-13-134>.
27. Primer3—New Capabilities and Interfaces / A. Untergasser [и др.] // Nucleic Acids Research. — 2012. — Т. 40. — e115. — DOI 10.1093/nar/gks596. — URL: <http://dx.doi.org/10.1093/nar/gks596>.
28. QIAGEN. CLC Genomics Workbench / QIAGEN. — 2024. — URL: <https://digitalinsights.qiagen.com/>; (Version 24.0.1. RRID:SCR_011853).
29. R Core Team. R: A Language and Environment for Statistical Computing / R Foundation for Statistical Computing. — Vienna, Austria, 2026. — URL: <https://www.R-project.org/>.

30. Revised phylogeny of Rhizobiaceae: Proposal of the delineation of *Pararhizobium* gen. nov., and 13 new species combinations / S. A. Mousavi [и др.] // *Systematic and Applied Microbiology*. — 2015. — Т. 38, № 2. — С. 84—90. — DOI <https://doi.org/10.1016/j.syapm.2014.12.003>. — URL: <https://www.sciencedirect.com/science/article/pii/S072320201400191X>.

31. RIAM: A Universal Accessible Protocol for the Isolation of High Purity DNA from Various Soils and Other Humic Substances / A. G. Pinaev [и др.] // *Methods and Protocols*. — 2022. — Т. 5, № 6. — DOI 10.3390/mps5060099. — URL: <https://www.mdpi.com/2409-9279/5/6/99>.

32. Rozen S., Skaletsky H. J. Primer3 on the WWW for General Users and for Biologist Programmers // *Bioinformatics Methods and Protocols: Methods in Molecular Biology* / под ред. S. Krawetz, S. Misener. — Totowa: Humana Press, 2000. — С. 365—386.

33. Saitou N., Nei M. The neighbor-joining method: a new method for reconstructing phylogenetic trees // *Molecular Biology and Evolution*. — 1987. — Т. 4, № 4. — С. 406—425. — DOI 10.1093/oxfordjournals.molbev.a040454.

34. SantaLucia J. A unified view of polymer, dumbbell, and oligonucleotide DNA nearest-neighborthermodynamics // *Proceedings of the National Academy of Sciences*. — 1998. — Т. 95, № 4. — С. 1460—1465. — DOI 10.1073/pnas.95.4.1460. — eprint: <https://www.pnas.org/doi/pdf/10.1073/pnas.95.4.1460>. — URL: <https://www.pnas.org/doi/abs/10.1073/pnas.95.4.1460>.

35. SantaLucia J. J., Hicks D. The Thermodynamics of DNA Structural Motifs // *Annual Review of Biophysics*. — 2004. — Т. 33. — С. 415—440. — DOI 10.1146/annurev.biophys.32.110601.141800. — URL: <https://doi.org/10.1146/annurev.biophys.32.110601.141800>.

36. seqfold / J. Timmons [и др.]; GitHub repository. — URL: <https://github.com/Lattice-Automation/seqfold>; (Version v0.10.2).

37. Staley J. T., Konopka A. Measurement of in situ activities of nonphotosynthetic microorganisms in aquatic and terrestrial habitats // *Annual Review of Microbiology*. — 1985. — Т. 39. — С. 321—346. — DOI 10.1146/annurev.mi.39.100185.001541.

38. treeio: an R package for phylogenetic tree input and output with richly annotated and associated data. / L.-G. Wang [и др.] // *Molecular Biology and Evolution*. — 2020. — Т. 37, вып. 2. — С. 599—603. — DOI 10.1093/molbev/msz240.

39. *vegan: Community Ecology Package* / J. Oksanen [и др.]. — 2026. — DOI 10.32614/CRAN.package.vegan. — URL: <https://CRAN.R-project.org/package=vegan>; (R package version 2.7-3).
40. *Wickham H. ggplot2: Elegant Graphics for Data Analysis.* — Springer-Verlag New York, 2016. — URL: <https://ggplot2.tidyverse.org>.
41. *Wickham H., Vaughan D., Girlich M. tidyr: Tidy Messy Data.* — 2025. — DOI 10.32614/CRAN.package.tidyr. — URL: <https://CRAN.R-project.org/package=tidyr>; (R package version 1.3.2).
42. *Wrobel G., Kokocinski F., Lichter P. AutoPrime: selecting primers for expressed sequences* // *Genome Biology*. — 2004. — Т. 5, № 5. — P11. — DOI 10.1186/gb-2004-5-5-p11. — URL: <https://doi.org/10.1186/gb-2004-5-5-p11>.
43. *Zuker M. Mfold web server for nucleic acid folding and hybridization prediction* // *Nucleic Acids Research*. — 2003. — Т. 31, № 13. — С. 3406—3415. — DOI 10.1093/nar/gkg595.
44. *QuantPrime—a flexible tool for reliable high-throughput primer design for quantitative PCR.* / S. Arvidsson [и др.] // *BMC bioinformatics*. — 2008. — Т. 9. — С. 465.

Приложение 1

Лист подготовки проб

Лист подготовки проб составленный перед секвенированием Illumina MiSeq представлен на Рис. П1.1.

Samples:

Primers:

Nº	PLANT	POP	GENE
1	ML	soil	<i>nodA</i>
2	GO	soil	<i>nodA</i>
3	TP	soil	<i>nodA</i>
4	ML	soil	<i>nodC</i>
5	GO	soil	<i>nodC</i>
6	TP	soil	<i>nodC</i>
7	ML	soil	<i>nifH</i>
8	GO	soil	<i>nifH</i>
9	TP	soil	<i>nifH</i>
10	ML	soil	<i>folC</i>
11	GO	soil	<i>folC</i>
12	TP	soil	<i>folC</i>
13	ML	soil	<i>ftsX</i>
14	GO	soil	<i>ftsX</i>
15	TP	soil	<i>ftsX</i>
16	ML	soil	<i>recJ</i>
17	GO	soil	<i>recJ</i>
18	TP	soil	<i>recJ</i>
19	ML	nod	<i>nodA</i>
20	GO	nod	<i>nodA</i>
21	TP	nod	<i>nodA</i>
22	ML	nod	<i>nodC</i>
23	GO	nod	<i>nodC</i>
24	TP	nod	<i>nodC</i>
25	ML	nod	<i>nifH</i>
26	GO	nod	<i>nifH</i>
27	TP	nod	<i>nifH</i>
28	ML	nod	<i>folC</i>
29	GO	nod	<i>folC</i>
30	TP	nod	<i>folC</i>
31	ML	nod	<i>ftsX</i>
32	GO	nod	<i>ftsX</i>
33	TP	nod	<i>ftsX</i>
34	ML	nod	<i>recJ</i>
35	GO	nod	<i>recJ</i>
36	TP	nod	<i>recJ</i>

GENE	TYPE	FORWARD	REVERSE	FULL LEN	INTER LEN
<i>nodA</i>	symb	BKTGYTRCGBCGTTTCAT	GTGRTTYCGCATVGCRTTR	220	153
<i>nodC</i>	symb	TYGGYGCBGTKATGTGTTG	TRTCWCGGAABGTRCTSCGT	333	266
<i>nifH</i>	symb	CKATGCCCHATYCGSGARAACAAG	TCTTTCTRAGCTCBGCGT	337	270
<i>folC</i>	chrom	TSGAYCAYCAGSCMTATCTCGG	GGCATTGGCRTATTGATG	352	285
<i>ftsX</i>	chrom	CATTTCGTSGGMGCSGAA	GTMGATSGTSCGCATGAC	360	293
<i>recJ</i>	chrom	GAYGTGTSGTCRTCAYCAC	TARGCVCGRTTGAGVCCCT	340	273

ILLUMINA adapters:

TYPE	ADAPTER	LEN
FORWARD	TCGTCGGCAGCGTCAGATGTGTATAAGAGACAG	33
REVERSE	GTCTCGTGGGCTCGGAGATGTGTATAAGAGACAG	34




Рис.П1.1. Лист подготовки проб включает в себя таблицу с перечислением образцов, таблицу IUPAC-последовательностей внутренних пар праймеров, таблицу последовательностей использованных адаптеров и фотографию электрофореграммы всех образцов

Результаты анализа бета-разнообразия

На рис. П2.1 представлены результаты метода главных координат (PCoA) на основе расстояний Брея–Кёртиса для всех шести генов. Статистическая значимость разделения образцов по субстратам оценивалась методом PERMANOVA.




Рис.П2.1. PCoA-ординации (расстояние Брея–Кёртиса) для шести генов. Образцы почвы (оранжевый) и клубеньков (синий). Как видно из графиков и значений R^2 , фактор субстрата не формирует статистически значимого разделения сообществ при данном объеме выборки.

Таблица П2.1

Результаты PERMANOVA (фактор — субстрат)

Ген	Тип	R^2	p -value
<i>nodA</i>	Симбиотический	0.109	0.8
<i>nodC</i>	Симбиотический	0.074	0.7
<i>nifH</i>	Симбиотический	0.148	0.7
<i>folC</i>	Хаускипинг	0.247	0.3
<i>ftsX</i>	Хаускипинг	0.201	0.6
<i>recJ</i>	Хаускипинг	0.183	0.7